

Secondary Babytalkmonitor: Vergelijken van verschillende Speech-to-text modellen.

Ontwikkeling van een Proof-of-Concept Applicatie.

Ayoub Ait Cheikh Ahmed.

Scriptie voorgedragen tot het bekomen van de graad van
Professionele bachelor in de toegepaste informatica

Promotor: Mevr. A. Bekkens

Co-promotor: Dhr. El. Baazizi

Academiejaar: 2023–2024

Eerste examenperiode

Departement IT en Digitale Innovatie .

**HO
GENT**

Afkortingenlijst

AI Artificiële Intelligentie.

ASR Automated Speech Recognition.

AWS Amazon Web Services.

CER Character Error Rate.

JWD Jaro Winkler Dinstance.

MER Match Error Rate.

MVVM Model View ViewModel.

STT Speech To Text.

UI User Interface.

WER Word Error Rate.

WIL Word Information Error.

WIP Word Information Preserved.

Woord vooraf

Voor u ligt mijn bachelorproef getiteld "Secondary Babyltalkmonitor: Vergelijken van verschillende Speech-to-Text Modellen". Dit essentiële onderdeel van mijn academische traject vormt de sluitsteen van mijn studie Toegepaste Informatica aan Hogeschool Gent. Deze scriptie is niet alleen het einde van een belangrijke etappe, maar ook de start van een spannende nieuwe fase in mijn professionele carrière in België als international student. Mijn avontuur begon met de uitdaging om de Nederlandse taal te leren, wat de basis legde voor mijn studies en mijn toekomstige professionele ontwikkeling in dit land. Deze reis heeft mij enorm geïnspireerd en voorbereid op de volgende stappen.

Ik wil graag mijn oprechte dank uitspreken aan mijn promotor Anneleen Bekkens en co-promotor El Hassan Baazizi, voor hun begeleiding en standvastig steun die van onschatbare waarde zijn geweest voor het bereiken van dit moment. Mijn dankbaarheid gaat ook uit naar mijn vrienden en familie, die mij door dik en dun hebben gesteund. Daarnaast wil ik de vrijwilligers niet vergeten, die essentiële bijdragen hebben geleverd aan het verzamelen van gegevens voor mijn onderzoek. Zonder hun hulp zou dit project niet tot stand zijn gekomen.

Al vanaf jonge leeftijd was ik gefascineerd door het oplossen van puzzels, een hobby die mij natuurlijk naar de wereld van de technologie en programmering leidde. Deze interesse evolueerde naar een diepe passie voor de computerwetenschappen, wat uiteindelijk resulteerde in een bijzondere aandacht voor de mogelijkheden van kunstmatige intelligentie **Artificiële Intelligentie (AI)**. Binnen het domein van AI heb ik een specifieke interesse ontwikkeld voor **Automated Speech Recognition (ASR)** technologieën. Het gebruik van deze geavanceerde technologieën in de gezondheidszorg biedt aanzienlijke mogelijkheden voor het verbeteren van de communicatie tussen zorgverleners en oudere patiënten. Dit potentieel strekt zich uit tot diverse aspecten van de gezondheidszorg, van diagnose en behandeling tot dagelijkse zorg en preventie.

Dit onderzoek richt zich op het evalueren van verschillende speech-to-text modellen om te bepalen welke het meest geschikt zijn voor het identificeren en monitoren van 'secondary babyltalk' of 'elderspeak', een specifieke communicatiestijl gebruikt in de interactie met oudere mensen. Aan het einde van deze studie is er een duidelijk overzicht van diverse speech-to-text modellen en hun nauwkeurigheid voor 1-op-1-gesprekken in het Vlaams. Dit onderzoek helpt bepalen welke modellen geschikt zijn voor integratie in een secondary babyltalk-applicatie.

Terwijl u door deze pagina's bladert, hoop ik dat u inzicht verkrijgt in de cruciale rol

die **ASR**-technologieën kunnen spelen in de verbetering van onze interacties en zorgpraktijken, en in hoe geavanceerde technologie kan bijdragen aan een empathischere en effectievere communicatie.

Ik wens u veel leesplezier en dank u voor uw interesse in mijn werk.

Ayoub Ait Cheikh Ahmed.

Antwerpen 21/04/2024

Samenvatting

In dit bachelorproefonderzoek worden diverse speech-to-text modellen, inclusief open source modellen, getest om te bepalen welk model het meest geschikt is voor de use case van spraak naar tekst in een secondary babytalk monitor. Vrijwilligers verzamelen verschillende steekproeven van Vlaamse accenten door hun audio-opnames te delen, die vervolgens worden gebruikt als dataset. Deze audio samples bestaan uit voorgemaakte scripts die vaak worden gebruikt in rusthuizen en ziekenhuizen, zoals voorbereiden om te slapen en medicatie innemen. De opnames worden getranscribeerd door meerdere AI modellen om een transcriptie te verkrijgen. Vervolgens worden de transcripties geëvalueerd met verschillende metrics zoals Word Error Rate (WER), Match Error Rate (MER), en Word Information Error (WIL).

Het doel van dit onderzoek is de meest effectieve methode voor het herkennen en transcriberen van 'Secondary Babytalk', een specifieke communicatiestijl gebruikt bij interacties met oudere patiënten, te identificeren. Door nauwkeurige evaluatie streven we ernaar het beste en meest efficiënte model te selecteren.

De literatuurstudie die aan de basis ligt van dit onderzoek, biedt een diepgaand inzicht in de beschikbare ASR-modellen en de nauwkeurigheidsmetrieken waarmee hun prestaties kunnen worden beoordeeld. De belangrijkste beoordelingscriteria die gebruikt werd, is de JIWER bibliotheek die verschillende metrieken gebruikt om een transcriptie te evalueren. De laatste helpt om de effectiviteit van elk model en de accuratie te meten.

Het onderzoek omvat een gedetailleerde analyse van verschillende ASR-modellen die momenteel op de markt beschikbaar zijn. Deze modellen worden systematisch getest en vergeleken om hun geschiktheid voor gebruik in de zorgsector te bepalen. Door het uitvoeren van een reeks benchmarktests wordt inzicht verkregen in welke modellen het beste presteren onder gevestigde evaluatiecriteria.

Daarnaast wordt in het onderzoek de impact van 'Secondary Babytalk' onderzocht, inclusief de manier waarop het vaak negatief wordt ontvangen door oudere patiënten, ondanks de positieve intenties van zorgverleners. Dit benadrukt de noodzaak voor verbeterde communicatiemethoden die respect tonen voor de autonomie en competentie van de oudere patiënt.

Op basis van de resultaten van de analyse zal dit onderzoek praktische aanbevelingen doen voor het kiezen van het meest geschikte ASR-model. Deze aanbevelingen zijn gericht op het optimaliseren van de communicatiepraktijken binnen de zorgsector en het verbeteren van de interactie tussen zorgverleners en oudere pa-

tiënten, wat uiteindelijk zal bijdragen aan een verhoogde levenskwaliteit en welzijn van deze patiëntengroep. Wat wordt ondersteund door het onderzoek van Sibian (2024).

Inhoudsopgave

Afkortingenlijst	iv
Lijst van figuren	xii
Lijst van tabellen	xiii
1 Inleiding	1
1.1 Probleemstelling	2
1.2 Onderzoeksvraag	3
1.3 Onderzoeksdoelstelling	3
1.4 Opzet van deze bachelorproef	3
2 Stand van zaken	5
2.1 Inleiding	5
2.2 Secondary Baby Talk	6
2.2.1 Definitie	6
2.2.2 Kenmerken	7
2.2.3 Gevolgen	7
2.3 Vergrijzing in Vlaanderen	8
2.4 Artificiële Intelligentie en Automatische Spraakherkenning	9
2.5 Communicatie in de Zorg	9
2.6 Analyse van ASR-technologieën	10
2.6.1 Beschikbare Modellen	10
2.7 Evaluatiemethoden en metrics	11
2.7.1 Belang van evaluatie binnen ASR	11
2.7.2 ASR Prestatie factoren	12
2.7.3 ASR Fouten detectie	13
2.7.4 ASR Fouttypes	14
2.7.5 Word Error Rate (WER)	14
2.7.6 Beperkingen van WER	15
2.7.7 Jaro-Winkler Afstand (JWD)	16
2.7.8 Character Error Rate (CER)	17
2.7.9 Word Information Lost (WIL)	18
2.7.10 Het belang van sampling en data verzameling	18
2.8 Beschikbaar ASR evaluatie tools	19
2.8.1 JIWER (Jitsi Word Error Rate):	19
2.8.2 Speech Recognition Evaluation:	19

2.9	Persoonlijke Bijdrage en Toekomstvisie	20
3	Methodologie	21
4	Het Onderzoek	23
4.1	Steekproefneming	23
4.2	Groundtruth en Transcripties van modellen	24
4.2.1	Audio-opname 1 - Antwerps	24
4.2.2	Audio-opname 2 - Limburgs	26
4.2.3	Audio-opname 3 - Brugs	28
4.2.4	Audio-opname 4 - Gents	30
4.2.5	Audio-opname 5 - Algemeen Nederlands	32
4.2.6	Evaluatie Resultaten	34
4.2.7	Analyse	36
4.2.8	Conclusie	40
4.3	Evaluatie Code	41
5	Proof of concept	44
5.1	Noodzaak voor een App: Voordelen van een mobiele applicatie als een ElderSpeak-monitor	44
5.2	Front-End Structuur	45
5.3	Back-end Structuur	51
5.4	Hosting backend	51
6	Conclusie	53
6.1	Discussie	54
6.1.1	Beperkingen van het Onderzoek	54
6.1.2	Aanbevelingen voor Toekomstig Onderzoek	54
7	Bijlagen	56
7.1	Bachelorproef Opgave	56
A	Onderzoeksvoorstel	58
A.1	Introductie	58
A.2	State-of-the-art	59
A.2.1	Probleemstelling	59
A.2.2	Spraak-naar-tekst	59
A.2.3	Beschikbaar modellen	60
A.2.4	Criteria	60
A.3	Methodologie	62
A.3.1	Fase 1: Applicatie opbouwen (November 2023 - Februari 2024)	62
A.3.2	Fase 2: Evaluatie en Selectie van Modellen (Februari 2024 - Maart 2024)	63

A.3.3	Fase 3: Dataverzameling en Analyse (Maart 2024 - April 2024)	63
A.4	Uitkomstverwachtingen en conclusie	64
Bibliografie		65

Lijst van figuren

1.1	Leeftijdsverdeling naar geslacht Vlaanderen (2023).	2
2.1	Een Vergelijking van Communicatiedynamieken: Benaderingen van Zorgverleners met Oudere patiënten (Williams e.a., 2005).	8
2.2	Berekening van WER voor een voorbeeldmodeloutput gegeven de grond- waarheid transcriptie (O'Connor, 2023).	15
2.3	Voorbeeld van een onnauwkeurige WER resultaat (O'Connor, 2023). . .	16
3.1	Het uitvoeringsplan voor de evaluatieprocedure.	22
4.1	Resultaat van Modellenprestaties adhv WER	36
4.2	Resultaat van Modellenprestaties adhv MER	37
4.3	Resultaat van Modellenprestaties adhv WIL	38
4.4	Resultaat van Modellenprestaties adhv Word Information Preserved (WIP)	39
4.5	Resultaat van Modellenprestaties adhv CER	40
5.1	Opstart van de mobiele applicatie: Toont het initiële laadscherm van de applicatie	47
5.2	Hoofdscherm van de mobiele applicatie: Toont het centrale menu en biedt uitleg over het gebruik van de app.	48
5.3	Aanvraag laden: Illustreert de interface tijdens een gegevensaanvraag, verbetert de feedback voor gebruikers door een laadspinner te tonen. .	49
5.4	Foutieve aanvraag: Legt de UI-reactie vast op een onsuccesvolle in- teractie met de server, en geeft gebruikers richtlijnen over mogelijke stappen om het probleem op te lossen.	50
5.5	Architectuur diagram van het project	52

Lijst van tabellen

4.1	Overzicht van de steekproeven	23
4.2	Referentie tekst van Audio-opname 1.	24
4.3	Resultaten van transcripties	25
4.4	Referentie tekst van Audio-opname 2.	26
4.5	Resultaten van transcripties	27
4.6	Referentie tekst van Audio-opname 3.	28
4.7	Resultaten van transcripties	29
4.8	Ground truth for Sample 4.	30
4.9	Referentie tekst van Audio-opname 4.	30
4.10	Transcriptie resultaten van Sample 4	31
4.11	Referentie tekst van sample 5.	32
4.12	Transcriptie resultaten van Audio-opname 5	33
4.13	Samenvatting van de Prestaties van Spraak-naar-Tekst Modellen bij Verschillende Steekproefopnamen	35

List of Listings


4.1 Evaluatie code	42
------------------------------	----

1

Inleiding

Het artikel van Vlaanderen ([2023](#)) biedt een gedetailleerde analyse van de Vlaamse leeftijdspiramide, die een vergrijzende bevolking toont met een brede bovenkant en een smalle basis. Deze bron bespreekt de significante aanwezigheid van de babyboomgeneratie binnen de huidige demografie en de stijgende proportie oudere volwassenen in de bevolking, in het bijzonder in kustgemeenten waar meer dan een derde van de bevolking ouder is dan 65 jaar. Daarnaast benadrukt het de krimpende jongere demografie, wat wijst op een dalend geboortecijfer.

Deze demografische schuiving brengt aanzienlijke uitdagingen met zich mee. Het vereist een herbeoordeling van de beschikbare middelen en een strategische benadering om de levenskwaliteit en zorg van de senioren te waarborgen. Dit onderstreept het fundamentele belang van onderzoek dat zich focust op het optimaliseren van de levenskwaliteit en de ondersteunende diensten voor onze senioren.



Figuur (1.1)

Leeftijdsverdeling naar geslacht Vlaanderen (2023).

Deze doelstelling zal worden bereikt door een grondige evaluatie van diverse transcripties dit door ASR modellen gegenereerd worden, met als doel het selecteren van de meest accurate transcriptie.

1.1. Probleemstelling

Deze bachelorproef confronteert de uitdaging van misverstanden en miscommunicatie die voortvloeien uit het gebruik van 'Secondary Babytalk' in de interacties tussen zorgverleners en oudere patiënten. Het onderzoeksprobleem richt zich op het identificeren van het meest effectieve speech-to-text model dat deze unieke vorm van communicatie kan decoderen. De noodzaak om een duidelijk, respectvol en verstaanbaar communicatiekader te waarborgen binnen de zorgsector, vormt de kern van deze probleemstelling. Daarbij is het essentieel dat het geselecteerde model accuraatheid combineert met sensitiviteit voor de nuances in taalgebruik bij oudere patiënten. Het belang van dit onderzoek komt tot uiting in de meerwaarde die het zal bieden voor oudere patiënten en studenten verpleegkunde. Door een verfijnde speech-to-text technologie te identificeren die 'Secondary Babytalk' nauwkeurig kan transcriberen, streven we naar het verbeteren van de communicatie in de zorgsector. Dit is niet alleen van cruciaal belang voor de waardigheid en het welzijn van ouderen, maar ook voor het onderwijs en de professionele ontwikkeling van toekomstige verpleegkundigen.

1.2. Onderzoeksvraag

De centrale onderzoeksvraag van deze bachelorproef zal als volgt zijn:

“Hoe kunnen we spraak-naar-tekstmodellen evalueren om te bepalen welk model optimaal presteert voor de specifieke usecase van spraaktranscriptie?”

Het beantwoorden van deze vraag is fundamenteel voor het verbeteren van de communicatie tussen zorgverleners en oudere patiënten. Om een grondiger en omvattend antwoord op deze vraag te formuleren, worden de volgende deelvragen onderzocht:

- Wat houdt een **Speech To Text (STT)** model precies in en waar bevindt het zich in de wereld van kunstmatige intelligentie?
- Welke modellen zijn beschikbaar op de markt om te testen?
- Wat zijn relevante criteria om dergelijke modellen te evalueren?

1.3. Onderzoeksdoelstelling

De hoofddoelstelling van deze bachelorproef is het selecteren van het meest accurate spraak-naar-tekstmodel dat beschikbaar is op de markt, om vervolgens gebruikt te worden in verdere studies gericht op de communicatie tussen zorgverleners en oudere patiënten.

Het succes van dit onderzoek zal concreet gemeten worden door de volgende punten:

- Een verzameling van divers opnames van accenten in België vrij van bias. Daarna het inzetten van een open-source evaluatiebibliotheek om de prestaties van diverse modellen objectief te kunnen vergelijken.
- Een duidelijk en concreet evaluatieresultaat verkrijgen, dat als solide basis dient voor de selectie van het meest nauwkeurige model.

Verder streven we naar het ontwikkelen van een proof-of-concept applicatie die de functionaliteiten van een 'Elderspeak' monitoringapplicatie voor studenten verpleegkunde vergemakelijkt.

1.4. Opzet van deze bachelorproef

De rest van deze bachelorproef is als volgt opgebouwd:

In Hoofdstuk 2 wordt een overzicht gegeven van de stand van zaken binnen het onderzoeksdomein, op basis van een literatuurstudie.

In Hoofdstuk 3 wordt de methodologie toegelicht en worden de gebruikte onderzoekstechnieken besproken om een antwoord te kunnen formuleren op de onderzoeksvragen.

In Hoofdstuk 4 wordt het onderzoek uitgevoerd, waarbij alle resultaten van de transcripties en evaluaties worden gepresenteerd. Op basis van deze gegevens wordt vervolgens een onderbouwde conclusie getrokken.

In Hoofdstuk 5 De focus zal liggen op het demonstreren van de ontwikkelde mobiele applicatie.

In Hoofdstuk 6, tenslotte, wordt de conclusie gegeven en een antwoord geformuleerd op de onderzoeksvragen. Daarbij wordt ook een aanzet gegeven voor toekomstig onderzoek binnen dit domein.

2

Stand van zaken

2.1. Inleiding

Het hoofdstuk over literatuurstudie vormt een essentieel fundament voor dit onderzoek, diep inzicht geeft in wat er al bekend is over het onderwerp. Door een gedegen literatuurstudie uit te voeren, kunnen we verschillende cruciale doelen bereiken die de basis leggen voor ons onderzoek.

In dit onderzoek worden verschillende **ASR** modellen die momenteel op de markt beschikbaar zijn, vergeleken aan de hand van specifieke nauwkeurigheidsmetrieken om het beste model te selecteren voor een nauwkeurigere identificatie van kenmerken van "Secondary Babytalk".

De benchmarking zal worden uitgevoerd door de prestaties van de verschillende modellen te vergelijken aan de hand van gevestigde criteria, zoals de **WER** en de **JWD**. Door middel van een gedetailleerde analyse van verschillende modellen zullen we inzicht krijgen in hun prestaties en geschiktheid voor het identificeren van 'secondary babytalk'.

Dit onderzoek zal resulteren in praktische aanbevelingen voor het selecteren van het meest geschikte model om de communicatie in de zorgsector te verbeteren, wat de algehele kwaliteit van zorg ten goede zal komen.

Alvorens hierop een antwoord te kunnen bieden, is het van belang inzicht te verwerven in wat er vergeleken dient te worden. Dit kunnen we verwezenlijken door te antwoorden op de volgende vragen:

1. **Definitie en Plaatsing van Speech-to-Text Modellen:**

- Wat omvat precies een spraak-naar-tekstmodel en waar situeert het zich binnen het domein van kunstmatige intelligentie?
- Hoe past een spraak-naar-tekstmodel in het bredere landschap van AI en wat zijn de kernprincipes achter deze technologie?

2. Beschikbare Modellen op de Markt:

- Welke specifieke spraak-naar-tekstmodellen zijn momenteel beschikbaar op de markt?

3. Relevante Criteria voor Model Evaluatie:

- Welke criteria zijn van belang bij het evalueren van spraak-naar-tekstmodellen?
- Hoe kunnen we de prestaties meten aan de hand van kwantitatieve data-analyse?
- Welke overwegingen zijn cruciaal voor het afstemmen van een model op de specifieke case van spraaktranscriptie?

2.2. Secondary Baby Talk

2.2.1. Definitie

Secondary Baby Talk, ook bekend als 'Elderspeak' is een vorm van spraak gericht aan oudere volwassenen. Het kenmerkt zich door objectieve aspecten zoals verhoogd volume en hoge toon en subjectieve aspecten zoals een neerbuigende toon. Het onderzoek van Balsis en Carpenter (2006) onderzoekt hoe mensen die niet direct betrokken zijn bij een gesprek "Elderspeak" beoordelen. een spreekstijl die vaak wordt gebruikt in communicatie met ouderen, en hoe deze beoordeling beïnvloed wordt door de leeftijd van de persoon die spreekt en hun relatie tot de oudere luisteraar. Ondanks de intentie om ouderen te helpen, wordt zowel het gebruik als het ontvangen van 'Elderspeak' negatief beoordeeld. Oudere patiënten worden gezien als minder welwillend, terwijl ontvangers als minder capabel en in een slechtere stemming worden beschouwd. Deze bevindingen benadrukken de negatieve implicaties van 'Elderspeak', ongeacht de leeftijd van de spreker of hun relatie tot de ontvanger. Dit suggereert dat 'Elderspeak' bijdraagt aan negatieve stereotypen en afhankelijkheid bij ouderen.

Dit communicatiegedrag, ondanks goede intenties, kan als neerbuigend worden ervaren door ouderen en kan hun zelfrespect, stemming en sociale betrokkenheid negatief beïnvloeden. Onderzoek suggereert dat dit soort spraak ouderen kan doen overkomen als minder competent, wat hun afhankelijkheid kan versterken en bijdraagt aan een negatieve cyclus van afnemende fysieke, cognitieve en functionele status (Balsis & Carpenter, 2006).

Een belangrijke bevinding van Williams e.a. (2005) is dat communicatie tussen zorgverleners en oudere patiënten vaak elementen van 'Elderspeak' bevat. Dit duidt op een onevenwichtigheid in de zorgrelatie. waarbij de zorgverlener mogelijk onbewust een taal en toon gebruikt die ouderen infantiliseren of neerbuigend behandelen. Zij beargumenteren dat het minimaliseren van het gebruik van 'Elderspeak' kan bijdragen aan het verbeteren van de communicatieomgeving, het bevorderen van de cognitieve en functionele vaardigheden van ouderen, en uiteindelijk kan

leiden tot een hoger welzijnsniveau en een verbeterde levenskwaliteit voor oudere patiënten.

2.2.2. Kenmerken

We wijzen op bepaalde kenmerken van 'Elderspeak' die leiden tot het idee dat deze manier van communiceren denigrerend of infantiliserend is wanneer deze wordt gebruikt tijdens interacties met oudere patiënten. 'Elderspeak' kan onder andere gekenmerkt worden door het gebruik van diminutieven, een tragere spraak-snelheid, een hoger volume, een eenvoudigere woordenschat, grammatica en verhoogde intonatie. Deze kenmerken worden vaak onbewust gebruikt in de veronderstelling dat ze de communicatie met oudere patiënten zouden vergemakkelijken of verbeteren (Williams e.a., [2005](#)).

Echter, de praktijk toont aan dat deze aanpak juist contraproductief kan werken. Oudere mensen kunnen zich hierdoor minder competent en gerespecteerd voelen, wat negatieve gevolgen kan hebben voor hun zelfbeeld en welzijn. Het is cruciaal voor zorgverleners en anderen die communiceren met oudere patiënten om bewust te zijn van deze kenmerken en om communicatiestrategieën te ontwikkelen die ouderen als volwaardige gesprekspartners behandelen, hun autonomie erkennen en hun capaciteiten respecteren (Williams e.a., [2005](#)).

2.2.3. Gevolgen


De gevolgen van 'Elderspraak', zoals besproken in het onderzoek van Grimme e.a. ([2015](#)), werpen licht op de impact van deze communicatiestijl op oudere patiënten binnen langdurige zorginstellingen.

Hoewel de intentie achter het gebruik van 'Elderspeak' kan zijn om de communicatie te vereenvoudigen en een gevoel van comfort te bieden, onthult de studie dat deze communicatievorm vaak wordt ervaren als neerbuigend en respectloos door de oudere ontvangers. Dit kan leiden tot een vermindering van het zelfrespect van de ouderen en een toename in hun gevoelens van afhankelijkheid en hulpeloosheid. Een significant inzicht uit de studie is dat 'Elderspeak' niet alleen de waardigheid van ouderen kan zich ontwikkelen, maar ook schadelijk kan werken in de zorgverlening. Het kan bijvoorbeeld de waarschijnlijkheid van weerstand tegen zorg verhogen bij individuen met dementie. Deze bevindingen benadrukken het belang van een meer gepersonaliseerde en respectvolle benadering van communicatie, die de autonomie en competentie van oudere patiënten erkent.

Door het bevorderen van een meer respectvolle communicatiestijl kunnen zorgverleners een positievere interactie met oudere patiënten ondersteunen, wat bijdraagt aan een verbeterde kwaliteit van zorg en leven. De resultaten van de studie suggereren een dringende noodzaak voor opleidings- en trainingsprogramma's voor zorgverleners om de bewustwording van de negatieve effecten van 'Elderspeak' te vergroten en vaardigheden te ontwikkelen voor effectievere communi-

catiepraktijken (Grimme e.a., 2015).

De meeste oudere patiënten geven de voorkeur aan een affirmatieve emotionele toon die zorg en controle op passende wijze in balans brengt, waarbij wordt gecommuniceerd dat de luisteraar bekwaam is om de boodschap te begrijpen en zelfstandig te handelen zoals geïllustreerd in figuur 2.1 (Williams e.a., 2005).



Figuur (2.1)

Een Vergelijking van Communicatiedynamieken: Benaderingen van Zorgverleners met Oudere patiënten (Williams e.a., 2005).

2.3. Vergrijzing in Vlaanderen

In de hedendaagse zorg- en welzijnssector is er een verschuiving zichtbaar van aanbodgestuurde naar persoonsgerichte zorg. Dit houdt in dat zorgverleners zorg op maat bieden, rekening houdend met de unieke behoeften, voorkeuren, wensen en verwachtingen van elke cliënt of patiënt.

Persoonsgerichte zorg vereist dat zorgverleners hun communicatiestijl aanpassen aan de zorgvragers, omdat kwaliteitsvol sociaal contact essentieel is en een positieve invloed heeft op zowel de fysieke als mentale gezondheid en levenskwaliteit van zorgvragers. Er is echter kritiek op de manier waarop communicatie vaak plaatsvindt tussen zorgverleners en zorgvragers. Deze communicatie wordt soms als ontoereikend en betuttelend beschouwd, waarbij zorgverleners specifiek voor dit onderzoek oudere patiënten, vaak een kinderlijke stijl hanteren, gekenmerkt door een overdreven toonhoogte, eenvoudige taal en het gebruik van verkleinwoorden en troetelnamen, een stijl die bekend staat als 'Secondary Babytalk' zie Bijlage 7.1.

In 2023 vertoont de bevolkingspiramide van het Vlaamse Gewest het kenmerkende

profiel van een vergrijzende bevolking, met een toenemend percentage van 65-plussers (21%) ten opzichte van 2000 (17%). Deze demografische verandering brengt nieuwe uitdagingen met zich mee in de zorgsector, met name de communicatie tussen zorgverleners en zorgbehoevenden in deze leeftijdscategorie (Vlaanderen.be, 2023).

2.4. Artificiële Intelligentie en Automatische Spraakherkenning

Fetzer (1990) analyseert AI, waarbij hij de complexiteit van het domein belicht en de uitdagingen bij het definiëren ervan bespreekt. Hij verkent de menselijke oorsprong van AI-entiteiten en de diverse aspecten van intelligentie binnen dit domein, van basisvaardigheden tot geavanceerd redeneren. Fetzer benadrukt de noodzaak van grondig onderzoek om de essentie van intelligentie in AI te begrijpen.

AI en ASR vormen twee essentiële componenten binnen de context van 'Elderspeak' monitoring, een cruciale praktijk in de gezondheidszorg voor oudere patiënten. Door AI en ASR te integreren in monitoringsystemen kunnen zorgverleners effectiever communiceren met oudere patiënten, wat leidt tot verbeterde zorgkwaliteit en patiënttevredenheid.

AI biedt geavanceerde technieken voor het analyseren en interpreteren van spraakgegevens, waardoor het mogelijk is om subtiele kenmerken en patronen in de spraak van oudere patiënten te identificeren. Dit omvat niet alleen het herkennen van woorden en zinnen, maar ook het begrijpen van de context, emoties en nuances in de spraak. Hierdoor kunnen zorgverleners beter inzicht krijgen in de behoeften en gezondheidsstatus van oudere patiënten, zelfs wanneer zij moeite hebben om zich verbaal uit te drukken (Jabraf, 2019; Young e.a., 2002).

ASR speelt een cruciale rol bij het omzetten van spraak naar tekst, waardoor gesproken informatie snel en nauwkeurig kan worden vastgelegd en geanalyseerd (Jabraf, 2017; Rabiner & Juang, 1993).

Dit stelt zorgverleners in staat om effectiever te communiceren met oudere patiënten, waarbij spraak wordt omgezet in geschreven tekst die kan worden opgeslagen, geanalyseerd en geïnterpreteerd voor verdere diagnostiek en behandeling.

2.5. Communicatie in de Zorg

Communicatie in de zorg, met name bij oudere patiënten, speelt een cruciale rol bij het leveren van effectieve en gepersonaliseerde zorg (Smith & Jones, 2020).

Ouderen kunnen vaak te maken hebben met verschillende gezondheidsproblemen en kunnen moeite hebben om zich duidelijk uit te drukken, waardoor communicatie met zorgverleners uitdagend kan zijn. Het is essentieel om een omgeving te creëren waarin zorgverleners in staat zijn om de behoeften en zorgen van oudere

patiënten effectief te begrijpen en hierop te reageren. Effectieve communicatie draagt bij aan het vergroten van de tevredenheid van patiënten, het verbeteren van behandelingsresultaten en het verhogen van de kwaliteit van de zorg.

AI en ASR spelen een steeds grotere rol in het verbeteren van communicatieprocessen in de zorg, inclusief die met oudere patiënten (Patel & Kumar, 2019).

Door die twee technologieën te incorporeren in zorgsystemen kunnen zorgverleners sneller en nauwkeuriger informatie vastleggen, interpreteren en communiceren. Dit stelt hen in staat om efficiënter te werken en beter in te spelen op de behoeften van patiënten. Bovendien kunnen AI-gebaseerde systemen zorgverleners ondersteunen bij het begrijpen van complexe spraakpatronen en het identificeren van belangrijke informatie, wat kan bijdragen aan het verbeteren van de kwaliteit en nauwkeurigheid van de communicatie (Patel & Kumar, 2019).

2.6. Analyse van ASR-technologieën

2.6.1. Beschikbare Modellen

AssemblyAI

AssemblyAI biedt een hoogwaardige ASR-service die specifiek is geoptimaliseerd voor een gemakkelijk ontwikkelaar ervaring en een breed scala aan talen en dialecten. Het is bekend om zijn robuustheid tegenover achtergrondgeluiden en biedt uitgebreide documentatie om integratie te vergemakkelijken (AssemblyAI, 2024).

Google Cloud STT

Google Cloud STT maakt gebruik van geavanceerde deep learning technologieën en biedt brede taalondersteuning, inclusief voor de Nederlandse taal. De dienst kan echter relatief kostbaar zijn bij grote volumes en soms ontbreken er aanpassingsopties voor specifieke vereisten (Google, 2024).

Microsoft Azure STT

Microsoft Azure STT is een flexibel ASR-systeem dat goed geïntegreerd kan worden binnen het Microsoft-ecosysteem en een ruime ondersteuning biedt voor talen, maar kan duur zijn bij grootschalige toepassingen en vereist soms aanzienlijke technische kennis voor maatwerk (Microsoft, 2024).

Amazon Transcribe

Amazon Transcribe heeft uitgebreide functies voor verschillende zakelijke sectoren, met inbegrip van de gezondheidszorg en klantenservice. Echter, de kosten voor de service kunnen hoog oplopen bij veelvuldig gebruik Amazon Web Services (2023).

Whisper

Whisper is een model van OpenAI die geoptimaliseerd is voor uiteenlopende accenten en presteert goed in lawaaierige omgevingen. Het is geschikt voor lange audiofragmenten en blijkt een WER van 14.8% voor basisschoolkinderen en 30.7%

voor middelbare scholieren te hebben bij de verwerking van Vlaamse spraak (OpenAI, 2023).

Wav2Vec 2.0

Wav2vec-U, ontwikkeld door Facebook AI, is een innovatieve benadering voor spraakherkenning die geen getranscribeerde gegevens vereist. Het model is vergelijkbaar met de prestaties van de best begeleide modellen van enkele jaren geleden, getraind met bijna 1000 uur aan getranscribeerde spraak. Deze methode, die spraakstructuren leert uit ongelabelde audio met behulp van een zelf-superviserend model en k-means clustering, is een belangrijke stap naar toegankelijker spraaktechnologie voor een breed scala aan talen en dialecten (Baevski e.a., 2021).

Hugging Face

Hugging Face's ASR-technologie, onderdeel van de Transformers-bibliotheek, biedt uitgebreide ondersteuning voor het ontwikkelen van geavanceerde spraak-naar-teksttoepassingen. Deze technologie stelt ontwikkelaars en onderzoekers in staat om toegankelijke en efficiënte ASR-oplossingen te creëren, dankzij de mogelijkheid tot het 'fine-tuning' van modellen zoals Wav2Vec2 en de ondersteuning van een breed scala aan talen en dialecten (Hugging Face, 2023).

Kaldi

Kaldi vertegenwoordigt een uitgebreid kader voor het uitvoeren van onderzoek naar spraakherkenning, waarbij een breed scala aan hulpmiddelen wordt geboden voor modellering en analyse. Ontwikkeld met als doel de ontwikkeling van robuuste en efficiënte ASR-systemen te vergemakkelijken. Kaldi onderscheidt zich door zijn ondersteuning voor lineaire algebra operaties, flexibiliteit in het modelleren van complexe spraakpatronen, en zijn open-source aard, wat samenwerking en innovaties binnen de gemeenschap van spraakherkenning aanmoedigt (Povey e.a., 2011).

2.7. Evaluatiemethoden en metrics

2.7.1. Belang van evaluatie binnen ASR

Evaluatie van ASR systemen is essentieel om te begrijpen hoe goed ze presteren vanuit het perspectief van menselijke gebruikers.

Deze laatste is cruciaal voor het meten van hun bruikbaarheid en het beoordelen van overgebleven uitdagingen, vooral bij het vergelijken van verschillende systemen.

Ondanks de vooruitgang van ASR tot commercieel bruikbare toepassingen, blijft een hoge foutenmarge in sommige spraakherkenningsdomeinen een belangrijke belemmering voor de bredere adoptie van spraaktechnologie, met name voor toepassingen die continue spraakherkenning met een grote woordenschat vereisen.

De aanhoudende aanwezigheid van ASR-fouten heeft de noodzaak versterkt om alternatieve technieken te vinden voor het automatisch detecteren en corrigeren van dergelijke fouten. De correctie van transcriptie-fouten is niet alleen cruciaal om de nauwkeurigheid van spraakherkenning te verbeteren, maar ook om te voorkomen dat fouten doorstromen naar volgende taalverwerkingsmodules, zoals machinevertaling (Errattahi e.a., 2018).

Het onderzoek van Errattahi e.a. (2018) focust op opkomende technieken die de foutenratio meten en de staat van het onderzoek naar de detectie en correctie van ASR-fouten evalueren. Automatische detectie en correctie van ASR-fouten is een belangrijk onderzoeksgebied geworden, niet alleen om de nauwkeurigheid van spraakherkenning te verbeteren, evenals het verhinderen dat fouten worden doorgegeven aan processen na herkenning, zoals machinevertaling en mens-computer interactie. Het doel is om fouten automatisch te detecteren, te classificeren en vervolgens gedeeltelijk of volledig te corrigeren, ongeacht het gebruikte ASR-systeem. Dit kan bijzonder effectief zijn, vooral wanneer het ASR-systeem wordt gebruikt als een 'black-box' waarbij de gebruiker geen toegang heeft om de kenmerken en modellen van het ASR-systeem af te stellen.

Het doel van ASR-evaluatie is om een vergelijkingscriterium te bieden tussen verschillende systemen of technieken en om de vooruitgang en prestaties op specifieke taken te meten op basis van foutenstatistieken. Er zijn twee essentiële aspecten gerelateerd aan ASR-fouten: de referentie-herkende afstemming, die het vinden van de beste woordafstemming tussen de referentie en de automatische transcriptie omvat, en de evaluatiemetrics die de prestaties van de ASR-systemen meten (McCowan e.a., 2004).

Volgens McCowan e.a. (2004) moeten de eigenschappen van een ideale evaluatiemaatstaf voor ASR als volgt zijn:

1. **Direct:** De maatstaf meet de ASR-component onafhankelijk van de ASR-toepassing.
2. **Objectief:** De maatstaf wordt op een geautomatiseerde manier berekend.
3. **Interpreteerbaar:** De absolute waarde van de maatstaf geeft inzicht in de prestatie.
4. **Modulair:** De evaluatiemaatstaf is algemeen genoeg om gedetailleerde toepassingsafhankelijke analyses mogelijk te maken.

2.7.2. ASR Prestatie factoren

ASR-prestaties worden beïnvloed door verschillende factoren, waaronder:

1. **Spreekervariabiliteit:** De akoestische modellen zijn meestal gebaseerd op een beperkte hoeveelheid spraakgegevens die sprekers kenmerken op een bepaald moment en in een bepaalde situatie. Echter, de stem kan veranderen door factoren als veroudering, ziekte, emoties en vermoeidheid, waardoor het

akoestische model mogelijk niet representatief is voor alle sprekers in al hun mogelijke staten.

2. **Variabiliteit in gesproken taal:** Spontane spraak, accenten en een hoge mate van uitspraakvariatie door dialecten en articulatie vormen bekende uitdagingen voor **ASR**. Met een grote woordenschat wordt het bovendien steeds moeilijker om voldoende gegevens te vinden om de taalmodellen te trainen, wat vaak resulteert in het gebruik van sub-woordenmodellen in plaats van woordenmodellen, wat de prestaties aanzienlijk kan verminderen.
3. **Mismatchfactoren:** Een van de grootste uitdagingen bij spraakherkenning komt door verschillen in opnamecondities tussen de trainings- en testfasen, vooral wanneer het spraaksignaal via telefoonlijnen wordt verkregen.
Verschillen in achtergrondgeluid, het transmissiekanaal en de opnameapparaten kunnen variabiliteit introduceren in de opnames, wat leidt tot een verminderde nauwkeurigheid van het systeem.

Deze factoren onderstrepen het belang van voortdurende verbetering en aanpassing van **ASR**-systemen om de uiteenlopende variabiliteiten en mismatchfactoren te kunnen accommoderen en daarmee de algehele systeemprestaties te verbeteren. Het onderzoek en de ontwikkeling van methoden voor het detecteren en corrigeren van **ASR**-fouten zijn daarom cruciaal voor het vergroten van de bruikbaarheid en acceptatie van **ASR**-technologieën in diverse toepassingen (Errattahi e.a., 2018).

2.7.3. ASR Fouten detectie

In de context van **ASR** is de detectie van fouten een kritiek aspect dat de bruikbaarheid en intelligentie van **ASR**-systemen in praktische toepassingen aanzienlijk kan verbeteren (Jiang, 2005).

Het primaire doel van foutdetectie binnen **ASR**-systemen, zoals uiteengezet in het onderzoek van Jiang (2005), is om de betrouwbaarheid van spraak-naar-tekst conversies te verhogen door effectief fouten in transcripties te identificeren. Dit doel is van cruciaal belang omdat zelfs geavanceerde **ASR**-technologieën te maken hebben met een significante foutmarge als gevolg van factoren zoals achtergrondgeluid, sprekersvariatie, en de complexiteit van taal zelf.

Foutdetectiemechanismen zijn ontworpen om onnauwkeurigheden in transcripties te identificeren, waarbij onderscheid wordt gemaakt tussen verschillende soorten fouten zoals substitutie, deletie, of invoeging. Een nauwkeurige detectie van deze fouten is essentieel voor daaropvolgende correctiestrategieën, die tot doel hebben de **ASR**-output dichterbij de daadwerkelijk gesproken inhoud te brengen. Verder is in het onderzoek aangegeven dat **ASR**-foutdetectie de basis vormt voor het verbeteren van de gebruikerservaring in applicaties die afhankelijk zijn van

spraakherkenning. Door de ontwikkeling van geavanceerde technieken voor fout-detectie en -correctie kunnen **ASR**-systemen niet alleen accurater worden, maar ook meer geïntegreerd in een breed scala aan toepassingen, variërend van spraak-gestuurde assistenten tot automatische ondertiteling (Jiang, 2005).

2.7.4. **ASR Fouttypes**

Automatische spraakherkenning **ASR** heeft aanzienlijke vooruitgang geboekt, maar blijft gevoelig voor fouten die de nauwkeurigheid en bruikbaarheid beïnvloeden. Er zijn meerdere typen fouten die in **ASR**-systemen kunnen voorkomen, elk met specifieke oorzaken en gevolgen (Errattahi e.a., 2018):

1. **Substitutiefouten:** treden op wanneer het **ASR**-systeem een verkeerd woord herkent in plaats van het gesproken woord. Dit kan te wijten zijn aan de gelijkenis in klank tussen woorden of aan de beperkte precisie van het systeem bij het onderscheiden van spraakklanken.
2. **Invoegfouten:** worden gekenmerkt door het onjuist toevoegen van woorden die niet door de spreker zijn uitgesproken. Deze fouten kunnen ontstaan door achtergrondgeluiden of door het systeem dat ten onrechte pauzes of geluiden interpreteert als woorden.
3. **Verwijderfouten:** ontstaan wanneer het **ASR**-systeem een gesproken woord niet detecteert of herkent, waardoor dit woord afwezig is in de transcriptie. Dit kan het gevolg zijn van een lage spreek snelheid, articulatieproblemen of wanneer het spraaksignaal wordt gemaskeerd door achtergrondlawaai.

Het verbeteren van de nauwkeurigheid van **ASR** en het verminderen van deze fouten vereist geavanceerde technieken, data-augmentatie en robuuste akoestische modellen die beter bestand zijn tegen variabiliteit in spraak en opnameomstandigheden (Errattahi e.a., 2018).

Ondanks deze uitdagingen biedt **ASR** enorme mogelijkheden voor toepassingen variërend van spraakgestuurd assistenten tot automatische ondertiteling, wat de motivatie vormt voor voortdurend onderzoek en ontwikkeling in dit veld (Errattahi e.a., 2018).

2.7.5. **Word Error Rate (WER)**

Automatische spraakherkenningssystemen **ASR** hebben de afgelopen tien jaar aanzienlijke vooruitgang geboekt, waarbij de **WER** naar voren is gekomen als de voornaamste maatstaf voor het evalueren van de prestaties van deze systemen (Ragavan, 2022).


WER is gebaseerd op het concept van de bewerkingsafstand en kwantificeert de nauwkeurigheid van **ASR** door de verhouding van invoegingen, verwijderingen en vervangingen ten opzichte van het totale aantal tokens in een zin te berekenen.

Deze maatstaf is bijzonder effectief voor talen zoals het Engels, die doorgaans één spelling voor elk woord hebben, waardoor **WER** de algehele correctheid nauwkeurig kan weerspiegelen door de getranscribeerde tekst te vergelijken met de oorspronkelijke spraak (Raghavan, 2022).

$$WER(w) = \frac{i + d + s}{N_t} \quad (2.1)$$

waarbij:

- i Is het aantal invoegingen.
- d Is het aantal verwijderingen.
- s Is het aantal substituties.
- N Is de totale aantal woorden.



Figuur (2.2)

Berekening van **WER** voor een voorbeeldmodeloutput gegeven de grondwaarheid transcriptie (O'Connor, 2023).

2.7.6. Beperkingen van WER

Ondanks het wijdverbreide gebruik van **WER** als een standaardmaat voor de prestaties van **ASR**-systemen, identificeert het onderzoek enkele belangrijke beperkingen van deze maatstaf. De studie van Kwint e.a. (2023) benadrukt dat **WER** niet als een absoluut percentage kan worden beschouwd vanwege het ontbreken van een bovengrens.


Dit impliceert dat **WER** alleen kan aangeven dat het ene systeem beter presteert dan het andere, maar niet noodzakelijkerwijs hoe goed een systeem absoluut is. Daarnaast is **WER** niet symmetrisch ten aanzien van deleties en invoegingen, waardoor het in lawaaiige omstandigheden meer dan 100% kan overschrijden door een onevenredige nadruk op invoegingen vergeleken met verwijderingen. Het onderzoek toont aan dat, hoewel **WER** effectief blijft voor toepassingen zoals dicteren waar fouten handmatig gecorrigeerd kunnen worden, er voor de meeste andere

soorten spraakherkenningssystemen, waarbij het doel verder gaat dan louter transcriptie, behoefte is aan alternatieve of aanvullende evaluatiekaders. Dit is vooral relevant in domeinen zoals geautomatiseerde medische rapportage, waar de nauwkeurigheid van de transcriptie directe gevolgen kan hebben voor de kwaliteit van de patiëntenzorg (Kwint e.a., 2023).

Door het analyseren van bestaande medische audio-data en het uitvoeren van een pilot-experiment, onderzoekt deze studie de invloed van elementen zoals accent, stemfrequentie en omgevingslawaaï op de kwaliteit van ASR-transcripties. De resultaten wijzen op de significante impact van lawaai op de WER, hoewel het experiment door een beperkt aantal deelnemers geen significante verschillen kon aantonen. Dit onderstreept het belang van verder onderzoek naar de effecten van lawaai, taal en verschillende ASR-technologieën op de nauwkeurigheid van spraakherkenning, vooral in kritieke toepassingen zoals medische rapportage.

Het gebruik van WER als enige maatstaf voor de evaluatie van spraakherkenningssystemen blijkt beperkt. Hoewel WER een indicatie geeft van de algemene prestaties, mist het nuances, vooral met betrekking tot disfluenties zoals vulwoorden (‘‘uh’’, ‘‘üm’’). Deze aspecten van spraak, die de denkprocessen van de spreker weerspiegelen, kunnen waardevol zijn voor de ene context maar overbodig voor de andere Kwint e.a. (2023).

Een discrepantie tussen de transcriptie van disfluenties door het model en de ‘grondwaarheid’ transcriptie kan leiden tot een onnauwkeurige WER. Daarom pleit deze analyse voor een evaluatiemethode die rekening houdt met de complexiteit en contextuele afhankelijkheid van spraak, wat zou resulteren in een accurater en relevanter beoordeling van spraakherkenningssystemen (O’Connor, 2023).



Figuur (2.3)

Voorbeeld van een onnauwkeurige WER resultaat (O’Connor, 2023).

2.7.7. Jaro-Winkler Afstand (JWD)

De Jaro-Winkler-afstand is een algoritme dat in twee delen is opgedeeld. Het eerste deel, de Jaro-implementatie, houdt rekening met de overeenkomende karakters tussen twee strings, ongeacht de volgorde. Als de overeenkomende karakters

in een andere volgorde staan, wordt een tolerantievenster gebruikt voor het aantal transposities. De Jaro-Winkler afstand wordt berekend met een formule die de overeenkomsten en transposities tussen de strings in acht neemt, waarbij gewichten kunnen worden toegepast om de invloed van verschillende factoren te moduleren (Rdazzi e.a., 2023).

Het tweede deel, de Winkler-aanpassing, verbetert de Jaro-score door extra gewicht toe te kennen aan strings die in de begin karakters overeenkomen. Dit reflecteert het idee dat overeenkomsten aan het begin van de strings belangrijker zijn voor de totale perceptie van gelijkenis tussen strings. De Jaro-Winkler-afstand wordt dan berekend door aanpassingen aan de oorspronkelijke Jaro-score toe te voegen op basis van de overeenkomst aan het begin van de strings en de totale lengte van de strings (Rdazzi e.a., 2023).

De JW tussen twee woorden X en Y kan berekend worden als volgt:

$$JW = \frac{1}{3} \left(\frac{m}{\text{lengte}(X)} + \frac{m}{\text{lengte}(Y)} + \frac{m - t}{m} \right) \quad (2.2)$$

Waarbij:

- m Is het aantal overeenkomsten.
- t Is het aantal transposities.

2.7.8. Character Error Rate (CER)

Het karakterfoutpercentage (CER) biedt een gedetailleerde methode voor het evalueren van **ASR** door de prestaties op karakterniveau te beoordelen, in tegenstelling tot het woordfoutpercentage (**WER**), dat beoordelingen op woordniveau uitvoert. **CER** is vooral nuttig in talen zonder duidelijke woordgrenzen of in situaties waar nauwkeurigheid op karakterniveau cruciaal is. Hoewel **WER** veel gebruikt wordt voor een alomvattende beoordeling in veel talen, maakt CER gerichte verbeteringen in **ASR**-systemen mogelijk, waardoor het een cruciale rol speelt in linguïstische en technische toepassingen die hoge nauwkeurigheid vereisen (Hugging Face, 2023).

$$CER = \frac{S + D + I}{N} \quad (2.3)$$

Waarbij:

- S Het aantal substitutiefouten.
- D Het aantal verwijderingsfouten.
- I Het aantal invoegfouten.
- N Het totale aantal karakters in de referentie.

2.7.9. Word Information Lost (WIL)

De **WIL** ratio is een evaluatiemethode voor de prestaties van spraak-naar-tekst transcripties. Deze methode meet het percentage foutief voorspelde woorden tussen de referentie tekst 'ground-truth' en de gegenereerde hypothese (hypothesis sentences).

WIL varieert van 0 (geen fouten) tot 1 (geen correcte voorspellingen). Het is een beter alternatief dan de Word Error Rate **WER** voor applicaties waarbij de hoeveelheid gecommuniceerde informatie belangrijker is dan de kosten van het maken van een bewerking.

Dit komt omdat beide maten vergelijkbare scores geven wanneer de fouten laag zijn, wat aangeeft dat de theoretische basis van de **WER** niet altijd relevant is. De formule voor het berekenen van WIL is als volgt:

$$WIL = 1 - \frac{H^2}{(H + S + D)(H + S + I)} \quad (2.4)$$

Waarbij:

- H Het aantal correct getranscribeerde woorden (hits)
- S Het aantal woordvervangingen (substitutions).
- D Het aantal woorddeleties (deletions).
- I Het aantal woordinvoegingen (insertions).

2.7.10. Het belang van sampling en data verzameling

Bij het evalueren van **ASR** systemen is het kiezen van de juiste steekproeven essentieel voor een nauwkeurige beoordeling. Het proces omvat de volgende stappen (Learning, 2023):

1. Kies een kleine steekproef van opgenomen spraak, zorgend voor diversiteit en representativiteit.
2. Transcribeer de steekproeven handmatig om referentietranscripten te maken.
3. Verwerk deze steekproeven door de **ASR**-service.
4. Normaliseer de door **ASR** gegenereerde hypothese transcripten voor consistentie.
5. Bereken de **WER** met een open-source tool.
6. Maak beoordelingen op basis van relevante metrieken.

Het is belangrijk om uitspraken zorgvuldig te selecteren om vooringenomenheid te vermijden en een verscheidenheid aan spraakcontexten op te nemen, zoals verschillende geluidsniveaus, sprekers en accenten (Learning, 2023).

Zowel wanneer het gaat om het evalueren ASR systemen als in andere onderzoeksgebieden, spelen steekproeftechnieken een cruciale rol. Hierbij worden verschillende methoden toegepast om ervoor te zorgen dat de verzamelde gegevens een nauwkeurige representatie vormen van de diversiteit aan spraakpatronen en omgevingsomstandigheden die in de echte wereld worden aangetroffen (Hugging Face, 2023):

1. **Willekeurige Steekproef:** Bij willekeurige steekproeven worden voorbeelden willekeurig geselecteerd uit de gehele populatie van belang. Dit zorgt ervoor dat alle spraakpatronen en omgevingsomstandigheden een gelijke kans krijgen om te worden opgenomen in het evaluatie dataset.
2. **Gestratificeerde Steekproef:** Gestratificeerde steekproeven verdelen de populatie in subgroepen op basis van criteria zoals sprekerskenmerken of omgevingsfactoren. Voorbeelden worden willekeurig geselecteerd uit elke subgroep, wat een evenredige vertegenwoordiging garandeert. Dit maakt gerichte evaluatie van ASR-prestaties mogelijk over verschillende demografische of omgevingsfactoren.
3. **Clustersteekproef:** Clustersteekproeven verdelen de populatie in clusters, zoals geografische regio's of organisatorische eenheden, waarbij willekeurig clusters worden gekozen voor evaluatie. Binnen elk cluster worden alle steekproeven of een willekeurige subset ervan opgenomen. Hoewel handig voor natuurlijk gegroepeerde populaties, kan dit leiden tot minder diversiteit als er grote variaties tussen clusters zijn.

2.8. Beschikbaar ASR evaluatie tools

2.8.1. JIWER (Jitsi Word Error Rate):

JIWER vertegenwoordigt een efficiënte en gebruikersvriendelijke Python-bibliotheek, specifiek ontworpen voor het evalueren van prestaties van ASR. Dit instrument faciliteert de kwantitatieve beoordeling van ASR-modellen door middel van diverse nauwkeurigheidsmetrieken, die cruciaal zijn voor het begrijpen en verbeteren van de betrouwbaarheid van spraak-naar-tekst conversies (Jitsi, 2023).

2.8.2. Speech Recognition Evaluation:

De "Speech Recognition Evaluation" tool van Syml.AI is een geavanceerde en toegankelijke hulpmiddel voor iedereen die werkt met spraak-naar-tekst of spraakherkenningssystemen. Deze tool stelt gebruikers in staat om de nauwkeurigheid van automatische transcripties, gegenereerd door spraakherkenningssoftware, te vergelijken met transcripties gemaakt door mensen. Dit is cruciaal voor ontwikkelaars, onderzoekers, en gebruikers die de prestaties van hun spraak-naar-tekstsystemen willen evalueren en verbeteren (Syml.AI, 2023).

2.9. Persoonlijke Bijdrage en Toekomstvisie

In mijn onderzoek richt ik mij op het evalueren van spraak-naar-tekst modellen met als doel de transcriptie van 'Secondary Babytalk' te verbeteren voor nauwkeurigere communicatie binnen de zorgsector. Dit streven naar grotere accuratesse in transcripties is essentieel om misverstanden te voorkomen en de dialoog tussen zorgverleners en oudere patiënten te optimaliseren. Door de meest effectieve modellen te identificeren en toe te passen, beoog ik een significante verbetering in de kwaliteit van zorgcommunicatie te realiseren. Daarnaast zal er een Proof of Concept (POC) worden geïmplementeerd die het geselecteerde model zal adapteren en gebruiken voor transcriptie doeleinden.

3

Methodologie


Dit hoofdstuk biedt een gestructureerd overzicht van de methodologische aanpak die is gehanteerd in dit onderzoek. Het is bedoeld om de lezer inzicht te geven in de onderzoeksopzet, de gehanteerde methoden en de rationale achter de gekozen aanpak. Het onderzoek is opgedeeld in verschillende fasen, elk met specifieke doelstellingen, deliverables, en onderzoeksmethoden. De onderstaande secties beschrijven deze fasen in detail.

De eerste fase van het onderzoek bestond uit een uitgebreide literatuurstudie, gericht op het verkennen van het bestaande kennisdomein met betrekking tot 'secondary babytalk', de beschikbare spraak-naar-tekst **ASR** modellen, en de criteria voor model evaluatie. Deze fase had als doelstelling het vaststellen van een theoretische basis voor het onderzoek.

In de literatuurstudie kwam een fase waarbij bepaalde **ASR** modellen uitgekozen werden voor een analyse. De keuze voor deze modellen was gebaseerd op de beschikbaarheid en ondersteuning van het Vlaamse en Nederlandse taal. Die modellen zullen dan gebruikt worden om de steekproefneming te transcriberen.

De volgende stap in het proces is het verzamelen van audio samples. Deze samples zullen vervolgens worden onderworpen aan de geselecteerde AI-modellen voor transcribering. Het doel is om elke sample te laten transcriberen door de AI-modellen. De resulterende transcribties, samen met de grondwaarheid 'Ground truth' transcribties, worden vervolgens gebruikt als parameters voor de Jiwer-bibliotheek om de relevante metrics te berekenen. Een diagram in figuur 3.1 toont de wijze waarop de evaluatieprocedure zal worden uitgevoerd.

Na het verzamelen van de resultaten van deze evaluatie, worden ze samengebracht en overzichtelijk gepresenteerd in een tabel. Deze tabel zal een gedetailleerd inzicht bieden in de prestaties van de AI-modellen op basis van verschillende metrics en criteria.

**Figuur (3.1)**

Het uitvoeringsplan voor de evaluatieprocedure.

Ten slotte zal er op basis van de analyse van de resultaten een beslissing worden genomen. Deze beslissing kan betrekking hebben op verdere optimalisatie van de AI-modellen, het identificeren van zwakke punten in het systeem, of het bepalen van de geschiktheid van de AI-modellen voor het beoogde gebruiksscenario.

4

Het Onderzoek

Het onderzoek begint met een overzicht van de steekproeven die zorgvuldig zijn geselecteerd om een representatief beeld te geven van verschillende accenten en variaties in de Nederlandse taal. De steekproeven omvatten een breed spectrum, waaronder een accent uit Antwerpen, Limburg, Brugge, Gent en ook een steekproef van algemeen Nederlands.

4.1. Steekproefneming

De steekproeven worden onderworpen aan zowel handmatige transcriptie (ground-truth) als transcribering door de gekozen AI-modellen. Deze stap zorgt ervoor dat we een vergelijking kunnen maken tussen de menselijke transcriptie en de prestaties van de AI-modellen.

Steekproef	Accent
Audio-opname 1	Antwerps
Audio-opname 2	Limburgs
Audio-opname 3	Brugs
Audio-opname 4	Gents
Audio-opname 5	Algemeen Nederlands

Tabel 4.1: Overzicht van de steekproeven

Na het verkrijgen van de transcripties worden ze geëvalueerd met behulp van de Jiwer-bibliotheek, waarbij verschillende metrics worden toegepast om de nauwkeurigheid en kwaliteit van de transcripties te meten. Deze evaluatie leidt tot een overzicht van de resultaten, waarbij de verschillende metrics in een tabel worden gepresenteerd voor een duidelijk inzicht in de prestaties van de AI-modellen.

Ten slotte wordt een grondige analyse van de resultaten uitgevoerd om trends, patronen en eventuele discrepanties te identificeren. Op basis van deze analyse wordt een weloverwogen beslissing genomen. Deze beslissing kan variëren van het selecteren van het meest geschikte AI-model voor een bepaald accent tot het identificeren van gebieden waar verdere verbeteringen nodig zijn in de transcriberingstechnologie.

4.2. Groundtruth en Transcripties van modellen

4.2.1. Audio-opname 1 - Antwerps

Ground truth
Dag Moniekske, het is tijd voor in ons trammeke te kruipen eh! allee eerst ons pyjamake aandoen en dan lekker in onze bedeke. zie wat ik hier heb, ons favorite boek. zal ik eens een stukske voorlezen zodat onze moniekske rustig. allez , nu ga ik de lampen uitdoen he suske. zeg maar slaapwel tegen jantje maan. Tot morgen !

Tabel 4.2: Referentie tekst van Audio-opname 1.

AI Model	Transcriptie
AssemblyAI	Dag Monixke, het is tijd om in ons trammetje te kruipen. Allee, eerst ons pyjama aandoen en dan lekker in ons bedje. Zie eens wat ik hier heb. Oude favorietenboek. Zal ik een stukje voorlezen zodat ons Monixke wat rustig kan worden? Allee, nu ga ik de lampjes uitdoen, hè zusje. Zeg maar sloppel tegen Janneke man.Tot morgen
WhisperAI	Dag Monique. Het is tijd voor in ons tremmen ik het te krompen. Eerst ons pizza met je hand doen en dan lek je in ons burkje. Ziet iets wat ik hier heb. Awe favorieten boek. Zal ik een stukje voorlezen zodat ons Monique bij rustig kan worden? Allee. Nee, ik ga de lampenke zut toe in de suetje. Zicht maar een sloppel tegen je jannige man. Tot meer je...
Google Cloud TTS	cosmonique je destijds vlinderstruiken te kruipen hè als eerst wel speciaal met je hand doen en dan lekker in ons werk en series wat dat ik hierin hou je favoriete stukje voorlezen dan moet ik even rustig kan worden nee zeg Slaapwel tegen je man tot morgen
AWS	dag Miek. Het is tijd voor in ons trammetje te kruipen, hè Allez. Eerst ons pyjama aandoen en dan lekker in ons beetje. Zie eens wat dat ik hier heb. O favoriete boek zal ik een stukje voorlezen, zodat ons moniek wat rustig kan worden. Allez, ik de lampes. Suske zegt maar sloppel tegen Janneke man tot morgen
Wav2Vec CLSR 53	degmoniekske dies tijd voor in ons trampiken te krampenen al je eerste o'ns pigamakjen honden in da lekirino's binnetje zie iets wat tek ik jierin ouwe favorieten boek zal je stuxke voorlezen toen zij ons monijkske wa rustiekemweren alle neig ong de lampejes ten toenissus je zicht maar sloppel teja je man tot merg je
Azure Transcribe	Dag Moniek Cje Het is tijd voor in ons trammetje te kruipen, hè? Alle eerst ons pyjama kan aandoen en dan lekker in ons bedje. Zie die is, wat denk ik hier hem oude favoriete boek zal ik een stukje voorlezen, zodat ons Monique waar rustig gaan worden. Alle Nei Gong de lampjes de toen is zusje, zegt Morse Oppel tegen Janneke man tot morgen

Tabel 4.3: Resultaten van transcripties

4.2.2. Audio-opname 2 - Limburgs

Ground truth
Had dog Georgette ja tis bedtijd he, ja komt laten we onze gezellige pyjama aantrekken en lekker in bed kruipen hier is uwe favoriete voorleesboek voor slapen gaan nog he, wilt ge dat ik er een stukske uit voorlees? Ale laten we de lampen uit doen en welterusten zeggen tegen de sterren, alé zoete Drome

Tabel 4.4: Referentie tekst van Audio-opname 2.

AI Model	Transcriptie
AssemblyAI	Ah, dat je zegt. Het is bedtijd voor ons. Ja, kom. Laten we maar onze gezellige pyjama aantrekken en lekker in bed kruipen. Hier is ook een favoriete voorleesboek voor slape- gaan nog, hè. Allee, wil je dat ik er een hoofdstukje uit voor- lees? Allee, laten we de lampen uit doen en wel ter ruste zijn tegen de sterren. Zoek de dromen.
WhisperAI	Ah, dat is je zet, ja, het is beter over ons, ja, kom. Dat doen we als ik gezellig het peegemaan trekken en lekker een bad- kruipen. Hier is ook een favoriet voorlets boek voor slapen, h□? Ah, die wordt strak er nog een stukje niet voorlets. En die gaat weer lampen uit en nu wel terwijl ze zeggen die gris tijden zoekt dat dromen.
Google Cloud TTS	Alex Er zaten altijd gezellig het aantrekken en dan lekker in bed kruipen Hier is ook mijn favoriete voorleesboek voor sla- pen gaan helemaal He wat zeker is dat we de lampen uit en welterusten zeggen tegen de sterren en zo dat dromen
AWS	Ah, dat Sergette. Ja, het is bedtijd, he, voor ons. Ja. Kom, la- ten we maar onze gezellige pyjama aantrekken. En lekker in bed kruipen. Hier is uw favoriete voorleesboek voor slapen gaan nog, he. Allee. Wil je dat ik er een hoofdstukje uit voor- lees. Allez. Laten we de lampen uitdoen. Wuis te zeggen tegen de sterren. Zoete dromen.
Wav2Vec CLSR 53	na halijkje zet te at hes pertijn ervoran schelkp wat doet maal als een gezalijge perzeman aan trekken dan lijk er een bud kruijpen hierzn we favoriet voorlees boek voor slapen gemel hen alleen wot zakker een hoofdstuks knit voor lees het elat wort lampen uitoen hen weal terrust te zeggen tegen de sterren zoete dromen
Azure Transcribe	Alex verzetten ja, Dat is per tijden en vooral ons ja, kom wat normaal onze gezellige pyjama aantrekken dan lekker in bed kruipen. Hier is ook een favoriete voorleesboek voor sla- pen gaan nog he? Alleen wat ducker een hoofdstukje het woord is. Laten we de lampen uitdoen en welterusten zeg- gen tegen de sterren zo ik dat Roma."

Tabel 4.5: Resultaten van transcripties

4.2.3. Audio-opname 3 - Brugs

Ground truth
lersi doarsi, eje gie tied veur e kleine medikoasjrituele? We gon behinnen met uze vitamienes te pakkn lik broave joenges e, iere je toverpille om je sterk en hezond te oedn. Mondje open we goan der helehans in en zukke broave patiente zieje

Tabel 4.6: Referentie tekst van Audio-opname 3.

AI Model	Transcriptie
AssemblyAI	lerse Doortse, heb je tijd voor een kleine meditatierituele? We gaan beginnen met onze vitamines te pakken zoals brave jongens. Hier, je toverpillen om je sterk en gezond te houden. Mondje open, we gaan er helemaal in. En zo een brave patiënt zie je.
WhisperAI	Eerst door ze. Hij zit voor het leven in de kwaas in het wielen. We hebben begin met de uur- en vitaal minderste parten. Ik brave jongens. Iedereen, je toverpellen om je sterke gezond-tuten, bonchoten, wat handen heel al in, en ze een braven patient zie je hier.
Google Cloud TTS	lerse dorsen dit voor de kleine decoratie rituelen We hebben geen bij de vitamine pillen om je sterk En zo'n mongool en ze hebben patiënten
AWS	kleitu. We gaan beginnen met uh uze vitamines te pakken. Gelijk brave jongens, he, hier je toverpillen om je sterk en gezond te doen. Mondje open. We gaan het er heel al in. En ze een brave patiënt zie je.
Wav2Vec CLSR 53	degmoniekske dies tijd voor in ons trampiken te krampenen al je eerste o'ns pigamakjen honden in da lekirino's binnetje zie iets wat tek ik jierin ouwe favorieten boek zal je stuxke voorlezen toen zij ons monijkske wa rustiekemweren alle neig ong de lampejes ten toenissus je zicht maar sloppel teja je man tot merg je
Azure Transcribe	lerse dorpse Hij heeft dit voor de kleine decoratie rituelen. We gaan beginnen met vitamines te pakken. Gelijk brave jongens, he, hier je tovert pelle om je sterke gezond doden. Bonjo hopen We gaan er helemaal in en ze brave patientia hier.

Tabel 4.7: Resultaten van transcripties

4.2.4. Audio-opname 4 - Gents

Tabel 4.8: Ground truth for Sample 4

Ground truth
Goedenavond Rogier, zeg het is tijd om in bed te kruipen, ik ga jou helpen om je pyjama aan te doen uhm en dan ga ik je ook helpen met in bed te gaan liggen goed? Hier ik ga jouw boek bij je leggen dan kun je nog wat lezen. Of had je graag dat ik een beetje voorlees nee? Goed. Ik ga dan de lampen uitdoen, slaapwel! en zoete dromen hé Rogier!

Tabel 4.9: Referentie tekst van Audio-opname 4.

Tabel 4.10: Transcriptie resultaten van Sample 4

AI Model	Transcriptie
AssemblyAI	Goedenavond, Roger. Het is tijd om in bed te kruipen. Ik ga je helpen met je pyjama aan doen en dan ga ik je ook helpen met je bed te halen liggen, goed? Hier, ik ga een boek bij je leggen, dan kun je nog wat lezen. Of had je graag dat ik een beetje voorlees? Nee? Goed. Ik ga dan de lampen uitdoen. Slep wel. Als je te dromen, he Roger.
WhisperAI	Hoi, na van Trojge, zet de stijt om een bat te crepen. Kij je op mijn epijsma aan doen en dan ga ik ook alp om mijn bat te halen. Je kan je een boek bij u legen dan kunnen nog wel lese. Of wat ik ga, ik ga ook een beetje voor lese. Nee? Ik ga dan de lampen uit doen, slap al. En zult je de droog naar Trojge?
Google Cloud TTS	Goedenavond Roger zet de tijd om in bed te kruipen kan je wat voor mij doen helpen mijn batterij leeg hoe kan je een boek bij jullie dan kunnen we nog wel lezen graag dat ik een beetje voorlees Nee hoe ga dan de lampen uit doen Slaapwel en zoete dromen naar Roger
AWS	Goedenavond. Roger. Het is tijd om in bed te kruipen. Ik ga u helpen met uw pyjama aandoen, um. En dan ga ik u ook helpen met in bed te gaan liggen. Goed, hier. Ik ga u een boek bij u leggen. Dan kunt u nog wat lezen. Of had u graag dat ik een beetje voorlees. Nee, goed. Ik ga dan de lampen uitdoen. Sle wel. En is u te dromen, he, Roger.
Wav2Vec CLSR 53	navond roser zijt de stijt om mijn bat te kruipen kan je hebben mi pigmar aandoen er een haak uwel kal en mijn batijleging hoe je ga u een boekbebelekker dan kunnen noegewallezen of wel jek graag je dak een betje voren is neen hoe ga dan de lampennetun slapel gaan ziut te dromen naar rozeer
Azure Transcribe	Goeienavond Roger zet de strijd om in bed te kruipen. Kan u op mijn pyjama aan doen en dan ga ik u ook app in mijn bed liggen. Goed, hier, ga je een boek bij u leggen, dan kunnen we nog wel lezen of wat ik graag dat ik een beetje voorlees. Nee, goed, Ik ga dan de lampen uit doen, slapen al en ze dromen naar hoge.

4.2.5. Audio-opname 5 - Algemeen Nederlands

Ground truth
Hallo, Andreke! Het is bedtijd voor ons, nietwaar? Laten we onze gezellige pyjama aantrekken en lekker in bed kruipen. Hier is je favoriete voorleesboek voor het slapengaan. Wil je dat ik je een hoofdstuk voorlees? Laten we de lampen uitdoen en welterusten zeggen tegen de sterren. Zoete dromen!

Tabel 4.11: Referentie tekst van sample 5.

Tabel 4.12: Transcriptie resultaten van Audio-opname 5


AI Model	Transcriptie
AssemblyAI	Hallo Andréke! Het is bedtijd voor ons, nietwaar? Laten we onze gezellige pyjama aantrekken en lekker in bed kruipen. Hier is je favoriete voorleesboek voor het slapengaan. Wil je dat ik je een hoofdzok voorlees? Laten we de lampen uitdoen en wel trots te zeggen tegen de sterren. Zo te dromen!
WhisperAI	Hallo Anderken, het is Bettehett voor ons niet waar. Laten we onze gezellige pijmer aantrekken en lekker in bedkruipen. Hier is je favoriete voorkom voor het slaap. Wil je dat ik je een hoofdschuk voorkom? Laten we de lampen uit doen en wel terug te zeggen tegen de sterren. Zo te dromen.
Google Cloud TTS	Hallo andrieke het is bedtijd voor ons niet waar Laten we onze gezellige pyjama aantrekken en lekker in bed kruipen voorleesboek voor het slapen gaan. Wil je dat ik je een hoofdstuk vol is laten we de lampen uit doen en welterusten zeggen tegen Sterre zoete dromen
AWS	Hallo Andreeke. Het is bedtijd voor ons niet waar. Laten we onze gezellige pyjama aantrekken en lekker in bed kruipen. Hier is je favoriete voorleesboek voor het slapen gaan. wil je dat ik je een hoofdstuk voorlees. Laten we de lampen uitdoen en wel terug te zeggen tegen de sterren zoete dromen.
Wav2Vec CLSR 53	halo an derieken het is bettijd voor ons nietwaar laten we onze gezellige piama aantrekken en lik je in bed kruipen hier is je favoriete voorlisboek voor het slapen gaan wil je dat ik je een hofdzuek voorlees laten we de lampen uitdoen en wel truse zeeën tegen de sterren zoe te domen
Azure Transcribe	Hallo Andre Ke? Het is bedtijd voor ons, niet waar? Laten we onze gezellige pyjama aantrekken en lekker in bed kruipen. Hier is je favoriete voorleesboek voor het slapengaan. Wil je dat ik je een hoofdstuk vol is? Laten we de lampen uitdoen en welterusten zeggen tegen de sterren zoete dromen.

4.2.6. Evaluatie Resultaten

Tabel 4.13: Samenvatting van de Prestaties van Spraak-naar-Tekst Modellen bij Verschillende Steekproefopnamen

Sample	Model	WER	MER	WIL	WIP	CER
sample 1	assemblyAI	0.6	0.57	0.79	0.20	0.26
	whisperAI	0.8	0.67	0.87	0.12	0.42
	googleSTT	0.85	0.82	0.95	0.04	0.50
	AWS transcriber	0.65	0.62	0.84	0.15	0.30
	wav2vec2	0.83	0.83	0.96	0.03	0.44
	azure	0.73	0.65	0.86	0.13	0.34
sample 2	assemblyAI	0.58	0.52	0.74	0.25	0.27
	whisperAI	1.01	0.86	0.97	0.02	0.47
	googleSTT	0.67	0.62	0.79	0.20	0.42
	AWS transcriber	0.61	0.56	0.78	0.21	0.27
	wav2vec2	0.92	0.89	0.98	0.01	0.42
	azure	0.67	0.61	0.83	0.16	0.33
sample 3	assemblyAI	0.58	0.52	0.74	0.25	0.27
	whisperAI	1.01	0.86	0.97	0.02	0.47
	googleSTT	0.67	0.62	0.79	0.20	0.42
	AWS transcriber	0.61	0.56	0.78	0.21	0.27
	wav2vec2	0.92	0.89	0.98	0.01	0.42
	azure	0.67	0.61	0.83	0.16	0.33
sample 4	assemblyAI	0.52	0.50	0.74	0.25	0.21
	whisperAI	0.81	0.75	0.92	0.07	0.42
	googleSTT	0.71	0.70	0.88	0.11	0.39
	AWS transcriber	0.61	0.56	0.78	0.21	0.27
	wav2vec2	0.84	0.84	0.96	0.03	0.43
	azure	0.67	0.61	0.83	0.16	0.30
sample 5	assemblyAI	0.20	0.19	0.31	0.68	0.05
	whisperAI	0.45	0.41	0.61	0.38	0.15
	googleSTT	0.43	0.40	0.57	0.42	0.15
	AWS transcriber	0.31	0.28	0.45	0.21	0.05
	wav2vec2	0.56	0.50	0.73	0.26	0.14
	azure	0.20	0.19	0.31	0.68	0.04


4.2.7. Analyse



Figuur (4.1)


Resultaat van Modellenprestaties adhv **WER**

De grafiek 4.1 toont de **WER** scores van verschillende AI-modellen voor Vlaamse accenten. AssemblyAI behaalt consequent de laagste **WER**-scores, wat wijst op de hoogste nauwkeurigheid.




Figuur (4.2)
Resultaat van Modellenprestaties adhv MER

Op basis van de MER-scores in de grafiek 4.2 kan worden geconcludeerd dat AssemblyAI de meest betrouwbare en nauwkeurige prestaties levert bij het matchen van transcripties.




Figuur (4.3)
 Resultaat van Modellenprestaties adhv **WIL**

Op basis van de **WIL**-scores in de grafiek 4.3 kan worden geconcludeerd dat AssemblyAI de meest betrouwbare en nauwkeurigste prestaties levert bij het transcriberen van Vlaamse accenten, met het minste informatieverlies.



Figuur (4.4)
 Resultaat van Modellenprestaties adhv **WIP**

Op basis van de WIP-scores in de grafiek 4.4 kan worden geconcludeerd dat AssemblyAI de meest betrouwbare en nauwkeurige prestaties levert bij het transcriberen van Vlaamse accenten, met het meeste behoud van informatie.

**Figuur (4.5)**

Resultaat van Modellenprestaties adhv CER

De grafiek 4.5 toont een algemeen lage CER voor alle modellen, wat wijst op een hoge nauwkeurigheid in karakterherkenning. Het model AssemblyAI vertoont consequent lage waarden, wat de betrouwbaarheid ervan verder bevestigt.

4.2.8. Conclusie

De analyse van de prestaties van verschillende spraak-naar-tekst modellen op verschillende Nederlandse dialecten toont significante variabiliteit in de uitkomsten over de diverse metrics: WER, MER, WIL, WIP, en CER. Opvallend is dat de WER-waarden variëren van zo laag als 0.20 voor assemblyAI in audio-opname 5 algemeenNederlands tot boven 1.0 voor whisperAI in audio-opname 2 Limburgs, wat duidt op inconsistente prestaties over de audio-opnames heen.

WhisperAI en assemblyAI tonen significante verschillen in prestatie, met whisperAI die over het algemeen hogere ratios vertoont, wat kan wijzen op mindere efficiëntie in het omgaan met dialectische variaties vergeleken met assemblyAI.

De CER, die de fouten op karakterbasis meet, toont een vergelijkbare trend, met lagere scores voor AssemblyAI in algemeen Nederlands maar hogere scores in meer regionaal gekleurde dialogen zoals die uit Brugge en Gent. Dit suggereert dat sommige modellen beter zijn in het algemene Nederlands dan in het verwerken van regionale accenten.

De variatie in WIL en WIP indiceert hoeveel informatie verloren gaat of behouden blijft tijdens de transcriptie, waarbij wav2vec2 consistent hoog scoort op het behoud van informatie over bijna alle audio-opnames. De resultaten suggereren dat geen enkel model universeel superieur is over alle metrieken, en dat de keuze voor een specifiek model kan afhangen van de specifieke eisen van de taak en de ken-

merken van het dialect.

4.3. Evaluatie Code

In deze code 4.1, wordt een tabel samengesteld die de prestaties van alle modellen weergeeft. De transcriptiegegevens, opgeslagen in een **JavaScript Object Notation (JSON)**-bestand, worden ingeladen. Vervolgens gebruikt men de Jiwer-bibliotheek om diverse meetwaarden, zoals **WER** en andere relevante metrieken, te berekenen. Na het berekenen worden deze gegevens opgeslagen in een **Comma Seperated Values (CSV)**-bestand voor verdere analyse.

Daarnaast zijn er aanvullende scripts beschikbaar die de transcripties verzorgen met behulp van modellen zoals Azure, Wav2Vec2 en Whisper. Deze scripts zijn opgenomen als bijlagen en kunnen worden geraadpleegd via de volgende link (A. Ait-CheikhAhmed, 2024). Voor andere modellen, namelijk AssemblyAI, Google Cloud **STT** en AWS Transcriber, wordt de transcriptie gegenereerd via hun respectievelijke interfaces, waarvoor geen apart script vereist is.

```

import json
import csv
from jiwer import wer, mer, wil, wip, cer

# functie om alle metrieken te berekenen adhv JWIR bib
def calculate_metrics(groundtruth, transcription):
    return [
        wer(groundtruth, transcription),
        mer(groundtruth, transcription),
        wil(groundtruth, transcription),
        wip(groundtruth, transcription),
        cer(groundtruth, transcription)
    ]

# path naar JSON DATA bestand
json_file_path = r'transcription_data.json'

# transcripties laden
with open(json_file_path, 'r') as f:
    transcription_data = json.load(f)

# table headers init
table_data = [['Sample', 'Model', 'WER', 'MER', 'WIL', 'WIP', 'CER']]

# Verwerk elke input en bereken de metrieken voor de transcriptie van elke
# dienst.

for entry in transcription_data:
    sample_name = entry['sample']

    assemblyai_metrics = calculate_metrics(entry['groundtruth'], entry['
        assemblyai_transcription'])
    whisperai_metrics = calculate_metrics(entry['groundtruth'], entry['
        whisperAI_transcription'])
    google_cloud_metrics = calculate_metrics(entry['groundtruth'], entry['
        google_cloud_stt_transcription'])
    aws_transcriber_metrics = calculate_metrics(entry['groundtruth'], entry['
        aws_transcriber_transcription'])
    wav2vec2_metrics = calculate_metrics(entry['groundtruth'], entry['
        wav2vec2_large_xlsr_53_dutch_transcription'])
    azure_metrics = calculate_metrics(entry['groundtruth'], entry['
        azure_transcription'])

    table_data.append([sample_name, 'assemblyAI'] + assemblyai_metrics)
    table_data.append(['', 'whisperAI'] + whisperai_metrics)
    table_data.append(['', 'google_cloud_stt'] + google_cloud_metrics)

```

```
table_data.append(['', 'aws_transcriber'] + aws_transcriber_metrics)
table_data.append(['', 'wav2vec2'] + wav2vec2_metrics)
table_data.append(['', 'azure'] + azure_metrics)

# Schrijf de tabel output naar een CSV bestand
csv_file_path = 'transcription_metrics.csv'
with open(csv_file_path, 'w', newline='') as file:
    writer = csv.writer(file)
    writer.writerows(table_data)

print(f"Data has been successfully written to {csv_file_path}")
```

Listing 4.1: Evaluatie code

5

Proof of concept

5.1. Noodzaak voor een App: Voordelen van een mobiele applicatie als een ElderSpeak-monitor

In de context van gezondheidszorg en sociale diensten, vooral bij het opleiden en uitrusten van studenten of zorgverleners in het omgaan met en communiceren met oudere individuen, speelt de integratie van technologie een cruciale rol. De ontwikkeling van een mobiele applicatie voor het monitoren en beheren van ElderSpeak is om meerdere redenen zeer voordelig:

1. Draagbaarheid:

Het meest opvallende voordeel van het gebruik van een mobiele applicatie is de draagbaarheid. Studenten en zorgverleners bewegen vaak door verschillende omgevingen - of het nu in onderwijsinstellingen, woonhuizen of tijdens dagelijkse zorgtaken is. Een mobiele applicatie stelt hen in staat om een krachtig controlegereedschap in hun zak te dragen. Deze mobiliteit maakt onmiddellijke toegang tot de functionaliteiten van de app mogelijk, zoals het opnemen van interacties en het in real-time analyseren van spraak, ongeacht hun locatie.

2. Onmiddellijke Resultaten:

Het gebruik van een mobiele applicatie voor ElderSpeak-monitoring maakt real-time analyse en feedback mogelijk. Zodra een interactie is opgenomen, kan de applicatie onmiddellijke feedback geven aan de gebruiker over de kwaliteit van hun communicatie. Deze onmiddellijke reactie is cruciaal voor leren en correctie ter plekke, waardoor studenten en zorgverleners snel hun communicatiestrategieën met ouderen kunnen aanpassen en verbeteren.

3. Verbeterde Gebruikerservaring:

Het gebruik van een mobiele applicatie voor ElderSpeak-monitoring maakt

real-time analyse en feedback mogelijk. Zodra een interactie is opgenomen, kan de applicatie onmiddellijke feedback geven aan de gebruiker over de kwaliteit van hun communicatie. Deze onmiddellijke reactie is cruciaal voor leren en correctie ter plekke, waardoor studenten en zorgverleners snel hun communicatiestrategieën met ouderen kunnen aanpassen en verbeteren.

Het gebruik van een mobiele applicatie voor ElderSpeak-monitoring maakt real-time analyse en feedback mogelijk. Zodra een interactie is opgenomen, kan de applicatie onmiddellijke feedback geven aan de gebruiker over de kwaliteit van hun communicatie. Deze onmiddellijke reactie is cruciaal voor leren en correctie ter plekke, waardoor studenten en zorgverleners snel hun communicatiestrategieën met ouderen kunnen aanpassen en verbeteren.

Mobiele applicaties kunnen worden ontworpen met rijke gebruikersinterfaces die intuïtief en boeiend zijn, wat de interactie van de gebruiker met het hulpmiddel verbetert. Met functies zoals touchgebaren, audiovisuele feedback en aanpasbare instellingen, kan een mobiele applicatie een veel toegankelijker en plezierigere ervaring bieden in vergelijking met traditionele methoden of desktopsoftware. Deze gebruiksvriendelijkheid vergroot de kans op regelmatig gebruik, wat de leercurves kan verbeteren en de naleving van de beste praktijken in de communicatie met ouderen kan bevorderen.

5.2. Front-End Structuur

De front-end van de ElderSpeak-monitoringapplicatie is gestructureerd met behulp van de **Model View ViewModel (MVVM)** architectuur. Dit ontwerp patroon is bijzonder geschikt voor het beheren van complexe data-interacties en zorgt voor een duidelijke scheiding van zorgen, wat de onderhoudbaarheid en schaalbaarheid van de applicatie verhoogt.

1. **Model:**

Het Model in MVVM vertegenwoordigt de data en bedrijfslogica van de applicatie. Het is verantwoordelijk voor het ophalen, opslaan en manipuleren van de data, vaak in interactie met een backendserver of lokale databases. Voor onze applicatie zou het Model de audiogegevens, analyseresultaten en eventuele gebruikersinstellingen beheren.

2. **View:**


De View in MVVM is verantwoordelijk voor het renderen van de gebruikersinterface. Het toont data van de ViewModel en stuurt gebruikerscommando's, zoals knopklikken, terug naar de ViewModel. De Views worden opgesteld via Jetpack Compose, een modern framework voor het bouwen van native UI's. Voor animaties worden Lottie-bestanden gebruikt, die een rijke en dynamische gebruikerservaring mogelijk maken.

3. **ViewModel:**

De ViewModel fungeert als een tussenpersoon tussen het Model en de View. Het handelt het grootste deel van de logica voor het weergeven af en overbruggt de kloof tussen de acties van de gebruiker en de data van de applicatie. Hierdoor zorgt de ViewModel ervoor dat de logica van de gebruikersinterface gescheiden blijft van de bedrijfslogica, waardoor de code gemakkelijker te lezen en te onderhouden is.


**Figuur (5.1)**

Opstart van de mobiele applicatie: Toont het initiële laadscherm van de applicatie




Figuur (5.2)

Hoofdscherm van de mobiele applicatie: Toont het centrale menu en biedt uitleg over het gebruik van de app.

**Figuur (5.3)**

Aanvraag laden: Illustreert de interface tijdens een gegevensaanvraag, verbetert de feedback voor gebruikers door een laadspinner te tonen.



Figuur (5.4)

Foutieve aanvraag: Legt de UI-reactie vast op een onsuccesvolle interactie met de server, en geeft gebruikers richtlijnen over mogelijke stappen om het probleem op te lossen.

5.3. Back-end Structuur

Het project, SecondaryBabyTalkMonitorApi, is ontwikkeld om de communicatie tussen zorgverleners en oudere patiënten te analyseren door middel van spraakherkenning en linguïstische analyse. De structuur van de API is systematisch georganiseerd binnen een Java Spring Boot framework, wat efficiënte request handling en service management faciliteert.


De kernfunctionaliteit is ondergebracht in verschillende packages die elk een specifiek aspect van de applicatie adresseren. De 'controller' package bevat de 'TranscriptionController' die verantwoordelijk is voor het verwerken van audiofile uploads en het initiëren van de transcriptieprocessen. De 'service' package omvat de 'TranscriptionService' die gebruik maakt van een AI-client, gegenereerd door de 'AiClientFactory', om audio naar tekst te transcriberen via de AssemblyAI-API.

De 'model' package bevat de 'TranscriptionResponse' klasse die de resultaten van de transcripties opslaat, waaronder successtatus, volledige transcriptie, en sets van specifieke woorden zoals verkleinwoorden en nietzeggende woorden.

De 'utility' package bevat de 'LinguisticAnalysis' klasse, die essentieel is voor de linguïstische analyse van transcripties. Deze klasse is specifiek ontworpen om patronen zoals verkleinwoorden en herhalende zinnen te detecteren, welke indicatief zijn voor 'secondary babytalk'. De algoritmen die gebruikt worden voor deze identificatie zijn gebaseerd op eerder onderzoek (Sibian, 2024) dat de kenmerkende elementen van 'secondary babytalk' heeft vastgesteld. Door deze geavanceerde analytische benaderingen te integreren, kan de klasse effectief bijdragen aan het ontrafelen van complexe taalpatronen die vaak voorkomen in de communicatie met oudere patiënten.

Deze API is bijzonder nuttig voor het identificeren van 'secondary babytalk' kenmerken in de communicatie, een essentiële factor voor het verbeteren van de interactie tussen zorgverleners en oudere patiënten. Dit alles toont een goed doordachte structuur die gericht is op het verbeteren van de zorgkwaliteit door geavanceerde technologieën in de linguïstiek en machine learning te integreren. De volledige broncode van de backend is beschikbaar in de GitHub repository AitCheikhAhmed (2024).

5.4. Hosting backend

**Figuur (5.5)**

Architectuur diagram van het project

Het architectuurdigram 5.5 beschrijft hoe de baby-monitor POC is opgebouwd, waarbij gebruik wordt gemaakt van zowel cloudgebaseerde diensten als geautomatiseerde workflows. Het hart van dit systeem is GitHub, gebruikt voor versie-controle met Git en voor het opslaan van Java-code, wat de basis vormt voor de applicatie-ontwikkeling.

De integratie en levering van updates worden geautomatiseerd door GitHub Actions, terwijl Terraform zorgt voor de provisioning van AWS-resources. Dit omvat het creëren van Docker-images die worden beheerd in Amazon Elastic Container Registry (ECR) en uitgerold via AWS AppRunner, wat het beheer en de schaalbaarheid van de applicatie vereenvoudigt.

Daarnaast bevat het diagram een specifieke verwijzing naar een automatisch spraakherkenningsmodel (ASR) en een front-end ontwikkeld in Kotlin voor mobiele apparaten. Deze combinatie biedt een robuuste en gebruikersvriendelijke mobiele ervaring, geoptimaliseerd door de naadloze integratie van spraakgestuurde functies en efficiënte cloudservices.

6

Conclusie

Op basis van de gedetailleerde evaluatie en vergelijking van verschillende **ASR** binnen dit onderzoek, gericht op hun vermogen om diverse Belgische accenten te transcriberen, heeft men in dit onderzoek kunnen constateren dat het AssemblyAI-model uitblinkt in zowel nauwkeurigheid als consistentie. Deze conclusie steunt op gevestigde metrieken, die allemaal zijn geïntegreerd in de JIWER-bibliotheek.

De analyse van de dataset toont aan dat AssemblyAI consistent lagere **WER**-scores behaalt over verschillende steekproeven heen. Bijzonder in steekproef 5, scoort AssemblyAI aanzienlijk lager dan andere modellen met een **WER** van slechts 0.20, wat wijst op een superieure prestatie in het correct decoderen en transcriberen van spraak.

De uitmuntendheid van AssemblyAI wordt verder onderstreept door zijn prestaties op andere belangrijke metrieken namelijk **MER**, **CER**, **WIL**, **WIP**, waar het consequent beter scoort dan de concurrentie, wat bijdraagt aan zijn aanbeveling voor praktische implementatie.

De consistentie van het model, zelfs in de aanwezigheid van diverse accentvariaties, illustreert de robuustheid ervan voor gebruik in kritische toepassingen, zoals de monitoring van 'Secondary Babytalk' in zorginstellingen. Dit is van cruciaal belang, omdat een accurate en betrouwbare transcriptie direct de kwaliteit van communicatie en daarmee de zorg verbetert.

Deze bevindingen benadrukken het belang van een gedegen selectieproces van spraak-naar-tekstmodellen, vooral als deze ingezet worden in kritische zorgtoepassingen waarbij elke verbetering in communicatie direct bijdraagt aan de kwaliteit van leven van de patiënten. Het vermogen van AssemblyAI om consequent hoog te scoren op verschillende metrieken ondersteunt de keuze voor dit model als de beste optie voor het ondersteunen van communicatie met oudere patiënten binnen het Belgische dialectlandschap.

6.1. Discussie

6.1.1. Beperkingen van het Onderzoek

Ondanks dat de uitkomsten van dit onderzoek positief zijn, zijn er enkele beperkingen die de algemene conclusies kunnen beïnvloeden. Ten eerste is de steekproefomvang relatief beperkt, wat de algemene toepasbaarheid van de bevindingen kan inperken. De focus was voornamelijk gericht op vier specifieke Belgische accenten en één algemene Nederlandse steekproef; de prestaties van de geteste modellen in andere dialectische en linguïstische contexten zijn daarom niet onderzocht. Dit beperkt de mogelijkheid om de resultaten te generaliseren naar andere taalvariëaties.

Ten tweede was de variabiliteit in spraakcomplexiteit tussen de verschillende samples niet volledig gecontroleerd, wat suggereert dat sommige resultaten mogelijk beïnvloed zijn door verschillen in eenvoud of complexiteit van het taalgebruik. Daarnaast, hoewel AssemblyAI uitstekende resultaten liet zien, is de transparantie omtrent de parameters en training van het model niet volledig, wat vragen oproept over de reproduceerbaarheid van de studie.

Ten derde zijn de gebruikte opnames uitsluitend gemaakt in een stille omgeving. Dit aspect kan de uiteindelijke resultaten beïnvloeden wanneer er achtergrondgeluid aanwezig is tijdens de opnames. Het is daarom raadzaam om in toekomstig onderzoek ook de invloed van achtergrondgeluid op de prestaties van spraak-naar-tekstmodellen te onderzoeken.

Deze beperkingen suggereren dat verdere studies noodzakelijk zijn om de robuustheid en toepasbaarheid van de bevindingen te verifiëren, vooral in gevarieerde en realistische luisteromgevingen.

6.1.2. Aanbevelingen voor Toekomstig Onderzoek

Voor toekomstig onderzoek zou het waardevol zijn om de steekproefomvang te vergroten en meer diverse accentpatronen op te nemen om de robuustheid van de spraak-naar-tekstmodellen verder te testen.

Het zou ook nuttig zijn om een diepgaandere analyse uit te voeren van de soorten fouten die door de modellen worden gemaakt, om waardevolle feedback te verkrijgen.

Deze feedback zou onderzoek kunnen ondersteunen dat gericht is op het verfijnen van algoritmen met geavanceerdere machineleertechnieken, zoals deep learning, om de nauwkeurigheid te verbeteren en een betere generalisatie over verschillende soorten spraakgegevens te waarborgen.

Deze vooruitgang zou de inzetbaarheid van deze technologieën aanzienlijk verbeteren in een breder scala van zorginstellingen.

Verder heeft het onderzoek geleid tot nieuwe onderzoeksvragen die aanzetten tot verdere studies:

1. Hoe zouden de modellen presteren als de opnamen willekeurig in een lawaai-erige omgeving worden gemaakt ?
2. Hoe zouden de modellen presteren als de opnames langer duren en complexere accenten bevatten?
3. Kan het gekozen model verfijnd worden om een perfecte transcriptie te leveren?

7

Bijlagen

7.1. Bachelorproef Opgave

Secondary babytalk monitor: vergelijken van verschillende *speech-to-text* modellen*

* Bij dit project is er de mogelijkheid om verder te werken aan eerder gevoerd (bachelorproef)onderzoek.

Context

In de hedendaagse zorg- en welzijnssector is er een duidelijke verschuiving van aanbod-gestuurde zorg naar persoonsgerichte zorg. Zorgverleners erkennen steeds meer het belang van zorg op maat en benaderen bewoners, cliënten of patiënten als personen met unieke behoeften, voorkeuren, wensen en verwachtingen.

Persoonsgericht zorg verlenen betekent ook dat zorgverleners hun communicatiestijl afstemmen op zorgvragers. Het hebben van kwaliteitsvolle sociale contacten is een basisbehoefte. Er wordt bovendien gesteld dat sociaal contact een beschermend effect kan hebben op de fysieke en mentale gezondheid, alsook dat het een invloed heeft op de levenskwaliteit van zorgvragers. Hoewel we dus kunnen zeggen dat het contact tussen zorgverleners en zorgvragers van cruciaal belang is, wordt dat contact tussen beide partijen vaak als ontoereikend beschouwd. **Eén van de kritieken die luidt, is dat er vaak op een betuttelende of kinderlijke manier wordt gecommuniceerd met zorgvragers. Die communicatiestijl, die vaak *secondary babytalk* wordt genoemd, herkent men onder andere aan een overdreven toonhoogte (*nursery tone*) en stemvolume, het gebruik van eenvoudige woorden en zinnen en het veelvuldig gebruik van verkleinwoorden en troetelnamen.**

Nood

In eerder bachelorproefonderzoek van studenten **Toegepaste Informatica** (Sibian De Gussem, Benjamin Daems en Arne Govaerts) werd een applicatie ontwikkeld die kenmerken van *secondary babytalk* kan identificeren. Dergelijke applicatie biedt een grote meerwaarde in opleidingen waar student-zorgverleners worden getraind om een niet-betuttelende communicatiestijl te hanteren. De

bachelorproefonderzoeken van voorgenoemde TI-studenten tonen aan dat toonhoogte en stemvolume twee uitgesproken kenmerken zijn die de applicatie accuraat kan monitoren. Om bijkomende, **talige, kenmerken van *secondary babytalk* te kunnen monitoren, is het noodzakelijk om gesproken conversaties (bv. audiogesprek tussen zorgvrager en student-zorgverlener) accuraat om te zetten naar tekst.**

Onderzoek

In dit bachelorproefonderzoek **test je verschillende *speech-to-text* modellen, inclusief open source modellen, om te achterhalen welk model het meest geschikt is voor de gegeven use case om spraak naar tekst om te zetten.** Je werkt met gesprekken tussen zorgvrager en student-zorgverlener die Vlaams spreken. Het doel is om een zo nauwkeurig mogelijke transcriptie te krijgen waarop een verdere analyse van taal mogelijk is (zoals gebruik van verkleinwoorden en bijzonder korte zinnen).


Resultaat

Op het einde van deze studie is er duidelijk zicht op de verschillende (al dan niet *open source*) *speech-to-text* modellen die op de markt beschikbaar zijn en is er inzicht in hun accuraatheid voor de gegeven use case (1-op-1-gesprekken in het Vlaams). Op die manier draagt dit bachelorproefonderzoek bij tot de vraag welk(e) *speech-to-text* model(len) geschikt is/zijn om te integreren in de huidige *secondary babytalk*-applicatie.

Contactpersonen

Jorrit Campens (jorrit.campens@hogent.be)
- Hogeschool Gent, opleiding verpleegkunde

Lena De Mol (lena.demol@hogent.be) – lector DIT



Onderzoeksvoorstel

Het onderwerp van deze bachelorproef is gebaseerd op een onderzoeksvoorstel dat vooraf werd beoordeeld door de promotor. Dat voorstel is opgenomen in deze bijlage.

A.1. Introductie

In de hedendaagse zorg- en welzijnssector is er een verschuiving zichtbaar van aanbodgestuurde naar persoonsgerichte zorg. Dit houdt in dat zorgverleners zorg op maat bieden, rekening houdend met de unieke behoeften, voorkeuren, wensen en verwachtingen van elke cliënt of patiënt. Persoonsgerichte zorg vereist dat zorgverleners hun communicatiestijl aanpassen aan de zorgvragers, omdat kwaliteitsvol sociaal contact essentieel is en een positieve invloed heeft op zowel de fysieke als mentale gezondheid en levenskwaliteit van zorgvragers. Er is echter kritiek op de manier waarop communicatie vaak plaatsvindt tussen zorgverleners en zorgvragers. Deze communicatie wordt soms als ontoereikend en betuttelend beschouwd, waarbij zorgverleners specifiek voor dit onderzoek oudere patiënten, vaak een kinderlijke stijl hanteren, gekenmerkt door een overdreven toonhoogte, eenvoudige taal en het gebruik van verkleinwoorden en troetelnamen, een stijl die bekend staat als 'secondary babytalk'.

In 2023 vertoont de bevolkingsspiramide van het Vlaamse Gewest het kenmerkende profiel van een vergrijzende bevolking, met een toenemend percentage van 65-plussers (21%) ten opzichte van 2000 (17%). Dit demografische verandering brengt nieuwe uitdagingen met zich mee in de zorgsector, met name wat betreft de communicatie tussen zorgverleners en zorgbehoevenden in deze leeftijdscategorie.

De vergrijzing van de bevolking leidt tot een toename in het aantal ouderen die zorg nodig hebben, vaak met specifieke communicatiebehoeften. Dit kan variëren van gehoorproblemen tot cognitieve uitdagingen. Hierin ligt het belang dit mijn

onderzoek: Een applicatie ontwikkelen die kenmerken van ‘secondary babytalk’ kan identificeren aan de hand van bepaalde speech-to-text modellen die beschikbaar zijn op de markt. Deze modellen zullen met elkaar vergeleken worden aan de hand van specifieke criteria. Dit zal resulteren dat het meest accurate model verkozen kan worden Vlaanderen.be (2023).

A.2. State-of-the-art

A.2.1. Probleemstelling

De centrale vraag die bij dit eindwerk hoort, luidt als volgt:

”Hoe kunnen we spraak-naar-tekstmodellen evalueren om te bepalen welk model optimaal presteert voor de specifieke usecase van spraaktranscriptie?”

Het beantwoorden van deze vraag alleen is echter onvoldoende. Aan de hand van de volgende deelvragen kan een gedetailleerder en uitgebreider antwoord worden geformuleerd:

- Wat houdt een speech-to-text model in precies en waar bevindt het zich in de wereld van kunstmatige intelligentie?
- Welke modellen zijn beschikbaar op de markt om te testen?
- Wat zijn relevante criteria om dergelijke modellen te testen

A.2.2. Spraak-naar-tekst

Het begrijpen van de nuances tussen termen zoals spraakherkenning, stemherkenning en natuurlijke taalverwerking kan uitdagend zijn. In de loop van dit onderzoek heb is er een mogelijke verduidelijking geïdentificeerd voor deze conceptuele complexiteit.

(IBM, [g.d.](#)) defineert het als volgt:

Spraakherkenning, ook wel bekend als automatische spraakherkenning (ASR), computergestuurde spraakherkenning of spraak-naar-tekst, is een functie die een programma in staat stelt menselijke spraak te verwerken en om te zetten in geschreven tekst. Hoewel het vaak verward wordt met stemherkenning, richt spraakherkenning zich op de vertaling van spraak van een verbale vorm naar een tekstuele, terwijl stemherkenning alleen probeert de stem van een individuele gebruiker te identificeren.

Spraakherkenningsmodellen produceren een transcript van spraak in audiogegevens. Dit transcript kan op zichzelf worden gebruikt of verder worden verwerkt voor andere doeleinden, zoals het gebruik van grote taalmodellen om de inhoud van de spraak te analyseren (O'Connor, 2023).

Samengevat Spraakherkenning, ook bekend als automatische spraakherkenning (ASR), is de mogelijkheid van een programma om gesproken taal om te zetten naar geschreven tekst.

A.2.3. Beschikbaar modellen

Google Speech to Text

Google Cloud Speech-to-Text is een API van Google Cloud Platform die gesproken taal omzet in geschreven tekst. Het ondersteunt verschillende talen, real-time streaming en batchverwerking. Gebruikers kunnen de service aanpassen voor domeinspecifieke termen en het integreert naadloos met andere Google Cloud-services. De API biedt veilige en nauwkeurige spraakherkenning voor verschillende toepassingen. (Google, [g.d.](#))

AssemblyAI

Samengesteld door AI-experts, omvatten de spraak-AI-modellen van AssemblyAI nauwkeurige spraak-naar-tekst voor spraakgegevens (zoals gesprekken, virtuele vergaderingen en podcasts), sprekerdetectie, sentimentanalyse, hoofdstukdetectie, PII-verwijdering en meer (AssemblyAI, [g.d.](#)).

A.2.4. Criteria

Uiteindelijk komt een juiste evaluatie neer op het aannemen van een wetenschappelijke benadering om ervoor te zorgen dat de resultaten accuraat, herhaalbaar en betrouwbaar zijn. Laten we nu onderzoeken hoe kunnen de gekozen modellen getest worden.

Word Error Rate (WER)

Automatische spraakherkenningssystemen (ASR) hebben de afgelopen tien jaar aanzienlijke vooruitgang geboekt, waarbij de Word Error Rate (WER) naar voren is gekomen als de voornaamste maatstaf voor het evalueren van de prestaties van deze systemen. WER is gebaseerd op het concept van de bewerkingsafstand en kwantificeert de nauwkeurigheid van ASR door de verhouding van invoegingen, verwijderingen en vervangingen ten opzichte van het totale aantal tokens in een zin te berekenen. Deze maatstaf is bijzonder effectief voor talen zoals het Engels, die doorgaans één spelling voor elk woord hebben, waardoor WER de algehele correctheid nauwkeurig kan weerspiegelen door de getranscribeerde tekst te vergelijken met de oorspronkelijke spraak.

(Raghavan, [2022](#)).

De WER kan berekend worden als volgt:

$$WER(w) = \frac{i + d + s}{N_t} \quad (\text{A.1})$$

waarbij:

- i is het aantal invoegingen
- d is het aantal verwijderingen
- s is het aantal substituties

- N is de totale aantal woorden

In het bijzonder telt WER inserties, waarbij het model een woord transcribeert dat niet aanwezig is, verwijderingen, waarbij het model een woord dat aanwezig is niet transcribeert en substituties, waarbij het model een woord onjuist transcribeert (O'Connor, 2023).

WER wordt beïnvloed door verschillende factoren, waaronder technische taal, branchespecifieke termen, accenten en ruis in de audiogegevens. Het herkennen van technische en gespecialiseerde taal vereist extra inspanning, terwijl accenten en diverse audiogegevens mogelijk aangepaste modellen nodig hebben voor nauwkeurige transcriptie. De aanwezigheid van ruis, veelvoorkomend in real-world scenario's zoals telefoongesprekken en diverse omgevingen, vormt een uitdaging voor de nauwkeurigheid van spraakherkenningssystemen (Gevirtz, 2018).

Echter zou WER alleen voldoende zijn als criterium omdat het fouten berekent op hetzelfde niveau, maar omdat het wat vaak niet het geval is moeten we een andere metriek introduceren (O'Connor, 2023).

Jaro-Winkler distance (JW)

De Jaro-Winkler Distance is een algoritme voor het meten van de gelijkenis tussen twee teksten en wordt voornamelijk gebruikt op het gebied van duplicatiedetectie. Dit algoritme is gebaseerd op het Jaro-Distance algoritme, dat is ontwikkeld door Matthew A. Jaro en later verder ontwikkeld door William E. Winkler en Thibaudeau door de Jaro Distance aan te passen om hogere gewichten te geven aan overeenkomsten in de voorvoegsels. Hoe hoger de waarde van de Jaro-Winkler Distance voor twee teksten is, hoe groter de gelijkenis tussen beide teksten. Een normale waarde van 0 duidt op geen gelijkenis, en een waarde van 1 duidt op de aanwezigheid van exacte overeenkomsten. De Jaro-Winkler-Distance formule wordt gebruikt om de afstand (d_j) tussen de twee teksten $S1$ en $S2$ te berekenen (Leonardo & Hansun, 2017).

De JW tussen twee strings kan berekend worden als volgt:

$$JW = \frac{1}{3} \left(\frac{m}{\text{length}(s1)} + \frac{m}{\text{length}(s2)} + \frac{m - t}{m} \right)$$

waarbij:

- m is het aantal overeenkomende karakters
- t is het aantal transposities

Anders gezegd Jaro-Winkler similarity is de maatstaf voor gelijkenis tussen twee teksten. De waarde van de Jaro-afstand varieert van 0 tot 1, waarbij 1 betekent dat de teksten identiek zijn en 0 betekent dat er geen gelijkenis is tussen de twee teksten.

A.3. Methodologie

Dit onderzoek richt zich op het evalueren van diverse speech-to-textmodellen om kenmerken van secondary babytalk te identificeren in gesprekken tussen zorgvragers en studentzorgverleners. De methodologie is opgedeeld in drie hoofdfasen:

A.3.1. Fase 1: Applicatie opbouwen (November 2023 - Februari 2024)

Back-end

De backend van de applicatie heeft de verantwoordelijkheid om een invoer te verwerken, wat in dit geval een geluidsopname van het gesprek is.

Vervolgens maakt het een API-oproep naar verschillende speech-to-textmodellen, afhankelijk van welk model de gebruiker heeft geselecteerd. Na het verkrijgen van de respons van het gekozen model, stuurt de backend deze respons door naar de frontend, waar deze verder wordt verwerkt.

In essentie fungeert de backend als een tussenliggende component die de communicatie tussen de frontend en de verschillende speech-to-textmodellen mogelijk maakt.

Het is echter van belang om Python te erkennen als een zeer aanbevolen programmeertaal voor AI-projecten. Deze keuze sluit aan bij het inzichtelijke perspectief van Damian Hill:

Python is uitgegroeid tot een veelzijdige programmeertaal voor kunstmatige intelligentie en datawetenschap, dankzij zijn eenvoud, grote gemeenschap, uitgebreide bibliotheken en naadloze integratiemogelijkheden. De leesbaarheid en robuustheid maken het een ideale keuze voor zowel beginners als ervaren ontwikkelaars. Met het voortdurend groeiende ecosysteem van Python is er geen twijfel dat het een cruciale rol zal blijven spelen in het veld van kunstmatige intelligentie en datawetenschap. (Hill, 2023).

Nochtans is de optimale programmeertaal voor backend-ontwikkeling, rekening houdend met mijn achtergrond en mijn streven naar verdere vaardigheidsontwikkeling, omvat het gebruik van Java in combinatie met Spring Boot. Gezien mijn aanzienlijke ervaring met Java, is deze keuze bijzonder voordelig. Bovendien biedt deze voorkeur potentiële voordelen voor studenten en onderzoekers die zich voor het eerst bezighouden met Java-programmering, met name in het kader van hun initiële betrokkenheid bij Speech to text Recognition.

Front-end

De front-end in deze context kan uiteindelijk een Android-toepassing zijn om de respons van de backend weer te geven. Dit kan verschillende voordelen hebben ten opzichte van een webtoepassing, zoals die in de vorige onderzoek.

Offline functionaliteit:

Een Android-app kan ontworpen worden om offline te werken, waardoor het elderspeak-

detectie kan blijven monitoren, zelfs wanneer het apparaat niet is verbonden met internet. Dit is vooral handig in scenario's waar een stabiele internetverbinding niet is gegarandeerd.

Gebruiksvriendelijk:

Een Android-app kan zeer handig zijn bij het werken in de gezondheidszorgsector. De smartphone kan naar een bepaalde locatie worden meegenomen en vervolgens gebruikt worden om de app-functionaliteit te gebruiken in plaats van te gedwongen worden een desktopcomputer te gebruiken. Bovendien kan de gebruiker een interactieve ervaring krijgen, bijvoorbeeld door meldingen te ontvangen over een proces of functionaliteit.

**A.3.2. Fase 2: Evaluatie en Selectie van Modellen
(Februari 2024 - Maart 2024)**

In deze fase van het onderzoek wordt een reeks specifieke stappen ondernomen om de geschiktheid van verschillende speech-to-textmodellen te beoordelen en uiteindelijk het meest geschikte model te selecteren voor verdere analyse.

Implementatie van Modellen in de Backend:

De geselecteerde speech-to-textmodellen worden geïntegreerd in de backend van de applicatie. Deze implementatie omvat het configureren van de modellen om te communiceren met de applicatie-infrastructuur en het mogelijk maken van verzoeken vanuit de frontend.

Evaluatie van Modellen:

De geïmplementeerde modellen worden onderworpen aan een grondige evaluatie op verschillende metrieken zoals in de vorige sectie vermeld wordt. Deze fase is cruciaal omdat het de basis legt voor het gebruik van een specifiek speech-to-textmodel binnen de applicatie.

**A.3.3. Fase 3: Dataverzameling en
Analyse
(Maart 2024 - April 2024)**

Het verzamelen van één-op-één-gesprekken tussen Vlaams-sprekende zorgvragers en student-zorgverleners staat centraal in deze fase. Hierbij streven we naar een zorgvuldige samenstelling van een representatieve dataset die een breed reeks aan contexten binnen de zorgsector bedekt.

In de volgende stap zullen we de geselecteerde speech-to-textmodellen evalueren en testen. Dit omvat de conversie van audiogesprekken naar tekst met behulp van het gekozen spraak-naar-tekstmodel. Om de kwaliteit van de transcripties te waarborgen, zal er ook een handmatige validatie plaatsvinden, uitgevoerd door een medestudent. Verdere details hierover ontvang je later. Deze evaluatie en testfase is cruciaal voor het begrijpen van de prestaties en toepasbaarheid van het gekozen

model in de context van ons onderzoek.

De samenvatting van bevindingen biedt een overzicht van de prestaties en karakteristieken van de onderzochte modellen, terwijl de vergelijking een diepgaande analyse geeft van hun sterke punten en beperkingen. De resulterende aanbevelingen zullen dienen als leidraad voor de keuze van het optimaal spraak-naar-tekstmodel dat het meest geschikt is voor de specifieke vereisten van de secondary babytalk-toepassing. Hierdoor streven we naar een effectieve implementatie van spraaktechnologie om de communicatie tussen zorgvragers en student-zorgverleners te verbeteren.

A.4. Uitkomstverwachtingen en conclusie

In deze sectie van mijn onderzoek, na de uitvoering van de methodologie en testen, verwacht ik dat de resultaten zullen aantonen dat het geselecteerde speech-to-textmodel succesvol is in het identificeren van kenmerken van secondary babytalk in 1-op-1-gesprekken tussen Vlaams-sprekende zorgvragers en student-zorgverleners. De geplande grafieken en metingen zullen waarschijnlijk de nauwkeurigheid van het model illustreren, vooral in diverse contexten binnen de zorgsector. Op basis van deze verwachte resultaten concludeer ik mogelijk dat het gekozen model een waardevolle bijdrage kan leveren aan het verbeteren van de communicatie tussen zorgvragers en student-zorgverleners. Dit zou resulteren in aanbevelingen voor de integratie van dit specifieke model in de secondary babytalk-applicatie, waardoor een verhoogde effectiviteit en relevantie worden bereikt in de context van de gezondheidszorg.

Bibliografie

- AitCheikhAhmed. (2024, april 14). *Back-End broncode van SecondaryBabyTalk API*. <https://github.com/AyoubAitcheikhahmed/secondaryBabyTalkMonitorApi>
- AitCheikhAhmed, A. (2024, mei 2). *Evaluatie Code van de methodologie: Secondary Babytalkmonitor: Vergelijken van verschillende Speech-to-text modellen*. https://github.com/AyoubAitcheikhahmed/latex-hogent-bachproef/tree/main/sample_evaluations
- Amazon Web Services. (2023). Amazon Transcribe: Automatic Speech Recognition [Accessed: 2023-09-28]. <https://aws.amazon.com/transcribe/>
- AssemblyAI. (g.d.). *Home / AssemblyAI docs*. Verkregen december 14, 2023, van <https://www.assemblyai.com/docs/>
- AssemblyAI. (2024). *AssemblyAI ASR Model*. Verkregen maart 16, 2024, van <https://www.assemblyai.com>
- Baevski, A., Hsu, W.-N., Conneau, A., & Auli, M. (2021). High-performance speech recognition with no supervision at all. <https://ai.meta.com/blog/wav2vec-unsupervised-speech-recognition-without-supervision/>
- Balsis, S., & Carpenter, B. D. (2006). Evaluations of Elderspeak in a Caregiving Context. *Clinical Gerontologist*, 29(1), 79–96. https://doi.org/10.1300/J018v29n01_07
- Errattahi, R., El Hannani, A., & Ouahmane, H. (2018). Automatic Speech Recognition Errors Detection and Correction: A Review. *Procedia Computer Science*, 128, 32–37. <https://doi.org/https://doi.org/10.1016/j.procs.2018.03.005>
- Fetzer, J. H. (1990). Artificial Intelligence: Its Scope and Limits. *Studies in Cognitive Systems*. <https://doi.org/https://doi.org/10.1007/978-94-009-1900-6>
- Gevirtz, M. (2018, april 11). *What is word error rate (WER)? - deepgram blog* [Deepgram]. Verkregen december 14, 2023, van <https://deepgram.com/learn/what-is-word-error-rate>
- Google. (g.d.). *Speech-to-text: Automatic speech recognition* [Google cloud]. Verkregen december 14, 2023, van <https://cloud.google.com/speech-to-text/>
- Google. (2024). Google Cloud Speech-to-Text. <https://cloud.google.com/speech-to-text>
- Grimme, T. M., Buchanan, J., & Afflerbach, S. (2015). Understanding Elderspeak from the Perspective of Certified Nursing Assistants. *Journal of Gerontological Nursing*, 41(11), 42–49. <https://doi.org/10.3928/00989134-20151015-05>

- Hill, D. (2023, september). Python — A Versatile Programming Language for AI and Data Science. Verkregen december 6, 2023, van <https://medium.com/@damian.hill/python-a-versatile-programming-language-for-ai-and-data-science-9f03bb99e22b>
- Hugging Face. (2023). *Uitgebreide Gids voor Automatische Spraakherkenning met Transformers*. Verkregen september 28, 2023, van <https://huggingface.co/docs/transformers/tasks/asr>
- IBM. (g.d.). What is speech recognition? | IBM. Verkregen december 14, 2023, van <https://www.ibm.com/topics/speech-recognition>
- Jabraf, A. (2017). Automatic Speech Recognition Systems: A Review. *International Journal of Computer Applications*, 176(20), 25–30.
- Jabraf, A. (2019). Advancements in Artificial Intelligence and Its Applications in Healthcare: A Review. *Journal of Healthcare Engineering*, 2019.
- Jiang, H. (2005). Confidence measures for speech recognition: A survey. *Speech Communication*, 45(4), 455–470.
- Jitsi. (2023). *JiWER: A Simple and Fast Package for Automatic Speech Recognition Evaluation* [Python package for evaluating ASR systems] (3.0.3). <https://github.com/jitsi/jiwer>
- Kwint, E., Zoet, A., Labunets, K., & Brinkkemper, S. (2023). How Different Elements of Audio Affect the Word Error Rate of Transcripts in Automated Medical Reporting, 179–187. <https://doi.org/10.5220/0011794100003414>
- Learning, A. M. (2023). *Evaluating an automatic speech recognition service* [2024-03-18]. <https://aws.amazon.com/blogs/machine-learning/evaluating-an-automatic-speech-recognition-service>
- Leonardo, B., & Hansun, S. (2017). Text Documents Plagiarism Detection using Rabin-Karp and Jaro-Winkler Distance Algorithms. *Indonesian Journal of Electrical Engineering and Computer Science*, 5, 462–471. <https://doi.org/10.11591/ijeecs.v5.i2.pp462-471>
- McCowan, I., Moore, D., Dines, J., Gatica-Perez, D., Flynn, M., Wellner, P., & Bourlard, H. (2004). Application-Oriented Evaluation of Speech Recognition Systems. <https://publications.idiap.ch/downloads/reports/2004/rr04-73.pdf>
- Microsoft. (2024). *Azure Speech-to-Text*. <https://azure.microsoft.com/en-us/services/cognitive-services/speech-to-text/>
- O'Connor, R. (2023). How to evaluate speech recognition models [News, tutorials, AI research]. Verkregen december 14, 2023, van <https://www.assemblyai.com/blog/how-to-evaluate-speech-recognition-models/>
- OpenAI. (2023). Whisper: OpenAI's Automatic Speech Recognition Model [Accessed: 2024]. <https://openai.com/blog/whisper>

- Patel, C., & Kumar, D. (2019). The role of artificial intelligence in healthcare: Current trends and future possibilities. *International Journal of Health Informatics*, 10(3), 112–130.
- Povey, D., Ghoshal, A., Boulianne, G., Burget, L., Glembek, O., Goel, N., Hannemann, M., Motlicek, P., Qian, Y., Schwarz, P., Silovsky, J., Stemmer, G., & Vesely, K. (2011). The Kaldi Speech Recognition Toolkit [IEEE Catalog No.: CFP11SRW-USB]. *IEEE 2011 Workshop on Automatic Speech Recognition and Understanding*.
- Rabiner, L. R., & Juang, B.-H. (1993). *Fundamentals of speech recognition*. Prentice Hall PTR.
- Raghavan, V. (2022). Is word error rate a good evaluation metric for speech recognition in indic languages? ArXiv. Verkregen februari 6, 2024, van https://www.academia.edu/93401304/Is_Word_Error_Rate_a_good_evaluation_metric_for_Speech_Recognition_in_Indic_Languages
- Rdazzi, A., Herchonvicz, A. L., Franco, C. R., & Jasinski, M. G. (2023). How Different Elements of Audio Affect the Word Error Rate of Transcripts in Automated Medical Reporting, 366–375. <https://ieeexplore.ieee.org/abstract/document/7507128>
- Sibian, D. G. (2024). Nursery Tone Monitor: detecteren van elderspeak via AI. <https://catalogus.hogent.be/catalog/hog01:000747773>
- Smith, A., & Jones, B. (2020). The importance of effective communication in healthcare. *Journal of Medical Communication*, 15(2), 45–58.
- Syml.AI. (2023). *Speech Recognition Evaluation* [Accessed: 2024-03-22]. <https://github.com/symlai/speech-recognition-evaluation>
- Vlaanderen, S. (2023, april 28). *Bevolking naar leeftijd en geslacht*. <https://www.vlaanderen.be/en/statistics-flanders/population/population-by-age-and-gender>
- Vlaanderen.be. (2023, juli 5). *Bevolking naar leeftijd en geslacht* (5. juli 2023, Red.) [www.vlaanderen.be]. Verkregen december 14, 2023, van <https://www.vlaanderen.be/statistiek-vlaanderen/bevolking/bevolking-naar-leeftijd-en-geslacht>
- Williams, K., Kemper, S., & Hummert, M. L. (2005). Enhancing Communication With Older Adults: Overcoming Elderspeak. *Journal of Psychosocial Nursing and Mental Health Services*, 43(5), 12–16.
- Young, S. J., Odell, J. J., Woodland, P. C., e.a. (2002). Hidden Markov model decomposition of speech and noise. *Acoustics, Speech, and Signal Processing, IEEE Transactions on*, 10(3), 442–455.